基于多源时空数据融合的城市人流预测与异常预警系统

实习项目总结报告（中文脱敏版）

项目	内容
实习岗位	网约车安全方向算法实习生
项目周期	5个月，约20周
报告组织	按七个项目里程碑的交付顺序展开
报告日期	2026年8月15日
数据说明	使用脱敏的城市网格化网约车流量样本描述技术方案，不披露业务敏感字段、原始订单或个人信息

摘要

城市网约车流量具有明显的日周期、周周期、区域异质性和突发波动。对于安全与运营团队而言，仅预测未来流量并不足够：系统还需要判断观测变化是否偏离正常规律，将离散异常网格合并为可处置事件，并给出事件类型、严重度和解释证据。本项目围绕“提前预知、及时发现、辅助处置”三个目标，完成了从多源数据治理、时空特征与图结构构建，到人流预测、异常检测、服务接口、交互式地图、可解释性与性能优化的端到端算法工程闭环。

数据侧将14段半小时级流入/流出序列统一为 `22,484 × 2 × 32 × 32` 的标准张量，并建立真实时间戳、稳定节点编号和训练专用数据缩放规则。针对早期按数组位置切窗可能跨越真实时间缺口的问题，项目补充了 gap-aware 连续性审计：每个“48步历史+48步未来”样本必须验证内部95个相邻时间差均为30分钟，最终测试集保留4,022个有效窗口。静态节点候选特征共41维，覆盖地理位置、路网、功能性POI、遥感、交通设施与历史统计；其中8维由全序列流量计算，存在泄漏风险，训练时予以删除，最终使用33维无泄漏静态特征。动态图输入包含流入、流出与7维真实时间/日历编码，共9维。

模型侧先完成ARIMA、Prophet、LSTM、GRU、GCN、GAT、STGCN等基线，再围绕显式空间先验、自适应邻接、时间自注意力和上下文门控设计项目版 AGFormer。该模型不是外部同名论文的严格复现，而是把 STGCN 的显式图传播、Graph WaveNet 的节点嵌入自适应邻接和 Transformer 的时间注意力组合为统一模块。项目同时将 Spacetimeformer 从轻量近似版本逐步对齐至 value/time embedding、given/missing embedding、encoder-decoder target token、local/global attention 与 cross-attention，用作更通用的架构对照。严格消融表明，简单扩大 Spacetimeformer 容量、增加未来时间上下文、多图全局加权、天气、完整日历和周期滞后均未带来稳定收益；从 Spacetimeformer 实验中发现的 linear residual head 则可稳定迁移至 AGFormer。最终四随机种子 AGFormer 集成在相同4,022个测试窗口上取得 h1 MAE 11.3019、24小时平均 MAE 15.9030、RMSE 30.2250、MAPE 35.44%，相对最佳单模型 MAE 进一步降低1.30%。

异常检测侧实现统计、重构和预测误差三条互补分支：3σ/IQR建立网格—时槽正常范围，VAE与Transformer自编码器在 weak-normal 样本上学习正常模式，最终预测模型的观测—预测残差提供第三类证据。验证集选定的软投票权重为0.70/0.20/0.10，决策阈值为0.56。系统将异常网格按时间连续性、空间IoU和质心距离合并为事件，并基于范围、形态、路网、持续时间和流入流出平衡度给出大型集会、交通拥堵、突发事件三类规则标签。最终输出131个候选事件；在 Level-A 弱标签口径下，timestep F1 为0.4912，事件级F1为0.4819。由于缺少权威事件真值且统计规则同时参与弱标签与融合，这些数字只能解释为固定弱标签口径下的一致性，不能等同于现实业务准确率。

系统侧封装 batch 与 realtime 微批两种流水线，FastAPI提供热力图、24小时预测、异常事件与统计查询，Streamlit地图支持实时热力、预测动画、事件详情、历史检索与三级预警。Week 7进一步完成注意力、TreeSHAP代理和异常上下文证据分析，并通过共享推理、统计缓存、关闭无用注意力权重、优化 DataLoader 与API派生缓存，将暖启动FP32端到端流水线由6.416秒降至4.613秒，实现1.39倍加速。项目最终形成了可复现、可解释、可服务化的城市人流预测与异常预警原型，同时明确记录数据真值、地理元数据、实时性和跨城市泛化方面的边界。

关键词： 城市人流预测；时空图神经网络；Transformer；多源数据融合；异常检测；FastAPI；可解释性

Contents / 目录

- 基于多源时空数据融合的城市人流预测与异常预警系统
  - 实习项目总结报告（中文脱敏版）
  - 摘要
- 1. 项目背景与需求分析
  - 1.1 业务背景
  - 1.2 功能需求
  - 1.3 非功能需求
  - 1.4 技术调研与选型原则
- 2. 总体技术路线与五个月工作安排
  - 2.1 端到端技术路线
  - 2.2 项目里程碑与20周周期
- 3. 数据处理、特征工程与图构建
  - 3.1 标准流量张量
  - 3.2 时间连续性与 gap-aware 切窗
  - 3.3 时间、日历与天气特征
  - 3.4 41维候选静态节点特征与33维最终输入
  - 3.5 四类候选图结构
- 4. 预测基线、指标与实验规范
  - 4.1 统一预测任务
  - 4.2 传统统计基线
  - 4.3 时序与图基线
  - 4.4 早期指标与最终口径的关系
- 5. 模型设计、消融与最终选型
  - 5.1 项目版 AGFormer 架构
  - 5.2 门控上下文融合
  - 5.3 Spacetimeformer 原版式对齐
  - 5.4 外生特征、周期滞后与多图消融
  - 5.5 Linear residual head
  - 5.6 最终预测结果与模型选择
- 6. 三路异常检测、事件融合与分类
  - 6.1 弱监督任务定义
  - 6.2 统计检测：3σ与IQR
  - 6.3 重构检测：VAE与Transformer AE
  - 6.4 预测误差检测
  - 6.5 分数校准与加权软投票
  - 6.6 从异常网格到时空事件
  - 6.7 事件分类与解释字段
- 7. 系统实现：端到端流水线、API、Web与预警
  - 7.1 Batch与realtime微批流水线

    - 7.2 FastAPI服务
    - 7.3 Streamlit地图与交互
    - 7.4 三级预警
- 8. 实验结果、可解释性分析与性能优化
    - 8.1 最终预测精度与误差结构
    - 8.2 时间注意力与空间自适应图
    - 8.3 TreeSHAP代理特征重要性
    - 8.4 异常上下文证据
    - 8.5 系统性能优化
    - 8.6 Optuna超参数优化方案
- 9. 综合结果、项目亮点与技术难点
    - 9.1 从研究原型到可运行系统
    - 9.2 主要亮点
    - 9.3 关键技术难点及处理
- 10. 评估边界、局限性与改进方向
- 11. 总结与展望
- 参考文献
- 附录：需求覆盖与主要交付物

1. 项目背景与需求分析

1.1 业务背景

本项目来自网约车安全算法实习场景。城市中的出行需求与人群活动会受到工作日节律、天气、节假日、商业区功能、交通设施和突发事件共同影响。传统人工看板能够呈现“现在有多少流量”，但很难同时回答未来24小时趋势、变化是否异常、异常发生在哪里以及应采取何种提醒。若只追求预测精度，系统只能输出连续数值；若只使用固定阈值，又容易把正常的早晚高峰误判为异常。因此，项目必须把预测、检测、事件化和服务化视为一个连续决策链，而不是几个独立模型。

从安全运营视角，核心问题可归纳为三类。第一是预判：未来半小时至24小时，各区域的流入规模如何变化，哪些区域可能出现显著增长。第二是检测：当前高流量是否已经被模型预期，还是偏离了历史与空间规律；绝对值很高但可预测的晚高峰不一定是异常，而绝对值不高但突然偏离局部模式的变化可能更值得关注。第三是响应：将若干网格和连续时间步整理为事件，给出位置、持续时间、候选类别、严重度和证据，供运营人员检索与核验。

1.2 功能需求

项目将业务目标拆为五类功能需求：

1. 人流预测。 使用过去24小时即48个半小时步，预测未来24小时48步的区域流入量，同时保留 h1、h3、h6、h12 和完整时域指标。
2. 异常检测。 同时实现统计偏离、正常模式重构误差和最优预测模型残差三种方法，避免单一规则决定所有结果。
3. 事件融合与分类。 将逐网格、逐时间步的异常掩码合并为时空事件，支持大型集会、交通拥堵和突发事件三类候选标签。
4. 查询与可视化。 提供按区域、时间、事件类型和预警等级查询的REST API；在Web端展示实时热力、未来24小时动画、事件标记和历史统计。
5. 分级预警。 将研究阶段的严重度映射为一般、重要、紧急三级提示，控制列表、横幅、弹窗和声音行为。

1.3 非功能需求

算法系统还需满足以下工程约束：

类别	要求
数据正确性	真实时间戳、连续窗口、训练集拟合缩放器、静态特征无未来泄漏
比较公平性	模型在相同窗口、相同切分和相同指标掩码下比较；超参数仅看验证集
资源安全	单GPU串行训练，限制batch和workers，支持断点、早停和显存门禁
可复现性	保存配置、随机种子、checkpoint、日志、摘要、数据与代码哈希
可解释性	对预测说明时间、空间和特征依赖；对异常说明三分支贡献和候选外部证据
服务稳定性	API不在请求中训练模型；推理产物原子发布；缺失产物时fail-fast或返回degraded
隐私与汇报	采用网格化、脱敏和聚合口径，不展示订单级轨迹或个人身份信息

1.4 技术调研与选型原则

Week 1并未直接选择最复杂模型，而是把论文机制转化为可验证假设。STGCN表明固定图卷积可以编码已知空间邻接，但其时间卷积和固定图可能限制远程关系；Graph WaveNet通过两个节点嵌入矩阵学习自适应邻接，为缺失或非局部关系提供数据驱动补充；Transformer提供全局时间注意力、残差、归一化和前馈层；Spacetimeformer把变量—时间对展开为token，代表更通用但计算更昂贵的时空注意力路线[1-4]。异常侧则把统计方法、VAE/Transformer AE重构和预测残差作为三种不同归纳偏置，而不是假定某一种方法天然最优。

调研最终形成四项原则：先建立传统与深度学习基线；显式图和自适应图都要通过消融验证；所有新增上下文特征必须在相同数据规则下比较；不能因模型理论上更通用就预设它一定优于任务先验更强的小模型。这些原则在Week 4的多轮负结果中被证明非常重要。

2. 总体技术路线与五个月工作安排

2.1 端到端技术路线

项目技术路线可概括为：

```
脱敏网格流量与外部数据
        ↓
时间规范化、缺口审计、数据清洗
        ↓
动态特征 + 静态节点特征 + 候选图结构
        ↓
传统/深度基线 → AGFormer / Spacetimeformer → 消融与多seed
        ↓
统计异常 + 重构异常 + 预测残差 → 加权融合
        ↓
空间连续事件合并 → 规则分类 → 严重度/三级预警
        ↓
Batch / realtime微批流水线 → FastAPI → Streamlit地图
        ↓
精度、解释性、延迟、内存与部署边界评估
```



图2-1　从数据治理、预测建模、异常融合到API与可视化的端到端技术路线。

贯穿全流程的统一坐标是 `timestamp × node_id × channel`。时间戳负责保证不同来源在同一30分钟槽对齐，`node_id` 保证流量、静态属性、图边和地图展示引用同一区域，channel则区分流入、流出和上下文。这个契约避免了“文件行号相同即代表同一区域”或“数组相邻即代表时间连续”等隐含假设。

2.2 项目里程碑与20周周期

为了与已有周报交付一致，正文继续使用Week 1–Week 7命名；它们表示七个里程碑包，而不是宣称整个项目只持续七个自然周。五个月工作量可回顾性分配如下：

周期	主要工作	对应里程碑
第1–3周	业务需求、论文调研、数据源与风险分析	Week 1
第4–7周	清洗、真实时间、外部数据、节点特征、图结构、数据报告	Week 2
第8–9周	ARIMA/Prophet、LSTM/GRU、GCN/GAT、STGCN基线	Week 3
第10–14周	AGFormer、Spacetimeformer、门控、多图、天气、日历、线性残差、多seed	Week 4
第15–16周	三类异常检测、融合、事件合并、分类、人工抽样	Week 5
第17–18周	端到端流水线、FastAPI、Web地图、三级预警、部署文档	Week 6
第19–20周	全面评估、注意力与SHAP、异常原因、性能优化、Optuna方案	Week 7

模型训练与选型占据最长周期，因为每次架构变化都需要数据规则核对、训练、日志检查、同窗口评估、消融和随机种子复验。数据工程位于模型之前，但并非一次性工作：真实时间修复、静态泄漏排除、天气对齐和地图显示校准都在后续实验中反向推动数据层完善。

3. 数据处理、特征工程与图构建

3.1 标准流量张量

原始流量由14个时间分段组成，每个时间步包含 inflow 和 outflow 两个通道，空间为32×32匿名网格。预处理首先解析本地日期槽，转换为统一时间戳，检查重复、缺失、负值、异常范围和数据类型，再将分段拼接为：

```
data.shape = (22,484, 2, 32, 32)
timestamp.shape = (22,484,)
dtype = float32 + datetime64
step = 30 minutes
```

空间维展平后共有1,024个节点，编号规则为 `node_id = row × 32 + col`。行方向由北向南，列方向由西向东。一个节点同时绑定动态流量序列、静态属性和图边。预估单格尺度约为1.33×1.73公里，但由于原始数据缺少完全权威的地理边界，训练只依赖稳定的行列拓扑；Web地图使用独立展示坐标校准，不能反向替代训练元数据。



图3-1　14段流量数据经过时间、空间和数据类型统一后形成标准节点—时间张量。

3.2 时间连续性与 gap-aware 切窗

早期实现按数组下标生成窗口，默认相邻记录必然相隔30分钟。然而分段拼接、停运日或缺测会造成真实时间跳跃。后续审计识别出73处非连续区间。若窗口跨越缺口，模型会把数小时或数天后的数据当成下一半小时目标，既破坏周期规律，也会产生不真实的低损失或高残差。

最终规则要求每个样本包含48步历史和48步未来，共96个时间点，其内部95个相邻差值必须全部等于30分钟。数据按时间顺序7:1:2切分，均值与标准差只在训练集拟合，再传给验证和测试。最终严格测试窗口为4,022个。所有Week 4最终模型、Week 5预测残差和Week 7评估均使用这一口径。

清洗阶段曾对绝对z-score大于5的点做插值，这有利于稳定预测，却可能抹去真实异常。因此报告将其视为原型限制：生产异常系统应并行保留不可变的原始镜像，预测训练可以使用清洗视图，异常核验则回看原始观测，避免把“清洗掉异常”与“检测异常”混为一谈。

3.3 时间、日历与天气特征

最终动态特征以真实时间戳计算，而不是用序号 `% 48` 推断：

特征	维度	作用
inflow / outflow	2	核心动态流量
slot sin / cos	2	半小时日内周期
weekday sin / cos	2	周周期
is_weekend	1	周末模式
is_holiday	1	法定节假日
workday	1	调休与补班语义

因此每个节点—时间步的动态输入为9维。日历模块对调休日和补班日做了显式区分，避免简单“周六日=休息日”的错误。天气数据构建了温度、湿度、风速、降水和天气状态等12个字段，并达到22,484/22,484时间戳对齐；但Week 4消融显示，天气与日历联合输入没有产生稳定MAE收益，因此天气未进入最终预测模型，仅在Week 7异常上下文分析中作为候选证据。

3.4 41维候选静态节点特征与33维最终输入

静态候选向量共41维，可分为八组：

特征组	维度	示例
地理位置	4	归一化经纬度、中心距离、环带位置
距离特征	2	最近交通枢纽、最近商业中心距离
路网密度	5	总道路、高速、主干、次干、支路密度
功能性POI	11	商业、餐饮、教育、医疗、办公、居住等
遥感	5	建成区、植被、水体、亮度等Landsat统计
历史流量统计	8	均值、p99、零值率、峰值、周末比、净流向、变异系数等
交通设施密度	3	地铁站、入口、公交站密度
线路与路由	3	轨道线路数、换乘枢纽、公交线路数

计数型特征采用 `log1p` 缩放，连续变量再进行归一化。功能性POI与交通设施分开，是因为早期交通类POI数量占比过高，使POI向量之间普遍相似，功能相似图容易退化。

其中第27–34列的8维历史流量统计由完整时间序列计算。如果直接用于训练，节点特征会包含验证和测试时期的均值、峰值等信息，形成静态形式的未来泄漏。最终加载器明确删除这8列，只保留33维真正静态的地理、路网、POI、遥感和交通设施特征。这个处理说明“特征在时间上不变化”并不等于“特征天然无泄漏”，其计算范围同样需要审计。



图3-2　41维候选静态特征的来源、预处理方式及最终33维无泄漏输入。

3.5 四类候选图结构

四张候选图共享1,024个节点，但表达不同关系：

1. 空间图 **`G_spatial`**。 使用Moore八邻域，权重为 $\exp(-d^2/1.5^2)$；正交邻居权重约0.641，对角邻居约0.411，共7,812条有向边，平均每节点7.6条。它编码最稳定的规则网格先验。
2. POI图 **`G_poi`**。 对11维功能性POI密度做 `log1p` 与L2归一化，按余弦相似度选择top-10邻居，共10,240条边。它允许相距较远但功能相似的区域交换信息。
3. 流量相关图 **`G_flow`**。 根据inflow序列的Pearson相关系数选择top-15正相关邻居，共15,255条边。该图可能重复历史输入信息，且最初由全序列构建，因此最终不作为生产图；若重启该方向，必须仅用训练期重建。
4. 交通图 **`G_transit`**。 根据轨道线路拓扑连接最多10站范围，双向边权按 $\exp(-hops/3)$ 衰减，共3,080条边，表达线路传播而非直线距离。



图3-3　空间、功能、历史相关与公共交通四种“相邻”关系的构图规则。

图文件统一保存 `edge_index(2,E)`、`edge_weight(E)` 和 `num_nodes`。Week 4多图实验并未证明语义越多越好：全局图权重最终被流量图占据92.18%，而POI和交通图几乎被抑制。最终模型只保留显式空间图，并另行学习自适应稠密邻接。

4. 预测基线、指标与实验规范

4.1 统一预测任务

Week 3的目标是建立从传统统计模型到图神经网络的可运行基线，而不是立即追求最终分数。预测对象为未来48步inflow，评价指标在反归一化后的原始流量尺度上计算。MAE反映平均绝对偏差，是后续预测残差异常检测的主指标；RMSE对少数大误差更敏感，用于审计尖峰风险；MAPE衡量相对误差，但在低流量区域不稳定，因此只在真实值非零并使用稳定项的掩码上报告。

报告中的 h1、h3、h6、h12 均为从预测起点到对应步数的累计指标，不是孤立的第3、第6或第12步；它们分别覆盖0.5、1.5、3和6小时，`avg` 覆盖完整24小时。这种定义便于观察误差如何随预测范围扩大，但在答辩中必须说明，否则容易被误解为“第12小时单点误差”。

4.2 传统统计基线

ARIMA对代表网格执行ADF平稳性检验、ACF/PACF分析、AIC阶数选择和Ljung–Box残差检验，最终用较集中的 `ARIMA(2,0,1)` 作为全局配置。Prophet启用日与周季节性，用一次拟合后外推的方式覆盖测试时段。初始实验中，ARIMA与Prophet的24小时平均MAE分别约44.73和43.81，显著弱于深度模型；Ljung–Box检验还显示ARIMA残差存在自相关，说明日周期与周周期中仍有可预测结构。

统计模型的价值并非分数领先，而是提供可解释下界：如果复杂模型没有显著超过它们，说明数据、切分或实现可能存在问题。同时，逐网格拟合的计算成本随节点数增长，难以充分共享不同区域之间的模式，也无法直接利用空间图和多源上下文。

4.3 时序与图基线

LSTM与GRU对所有节点共享时序编码器，GCN与GAT则把历史序列展平为节点特征后在空间图上传播。初始6小时输入实验中，LSTM/GRU平均MAE约29，明显优于GCN/GAT的33–37，说明仅有空间传播而缺少专用时序模块不足以处理24小时预测。将历史窗口从6小时扩展到24小时后，LSTM和GRU平均MAE降至约20.34和20.43；进一步扩到一周没有继续改善，提示超长序列并非简单增加输入即可获益。

STGCN进一步交替使用时间卷积和图卷积，验证了联合时空建模方向，但其固定图和卷积感受野仍限制灵活性。多图STGCN也说明，直接把多种关系叠加并不会自动得到有效融合。Week 3最重要的结论是：时间依赖是强基线，空间结构必须与时间模块联合使用；这直接推动Week 4采用时间自注意力加双图路径。

4.4 早期指标与最终口径的关系

Week 3部分结果生成于真实时间缺口审计之前，因此适合描述模型家族的相对趋势，不应与Week 4最终gap-aware结果直接混表。时间修复后，LSTM按相同4,022个测试窗口和多随机种子重跑，24小时平均MAE为19.4941、RMSE为36.8806、MAPE为34.64。后续所有最终选型均以这一严格版本为基线。

这次修正形成了项目的重要实验规范：实现完成并不意味着指标可直接使用；当数据规则变化时，关键基线必须重跑，旧结果必须保留来源和适用边界。模型比较优先使用同窗口、同切分、同seed或明确区分多seed均值与预测ensemble。

5. 模型设计、消融与最终选型

5.1 项目版 AGFormer 架构

项目中的AGFormer全称为 Adaptive Graph Transformer for Spatio-Temporal Prediction，是面向本任务的自主组合实现，不宣称复现外部同名论文，也不是完整STGCN与完整Graph　WaveNet的串并联。其单个block按以下顺序工作：

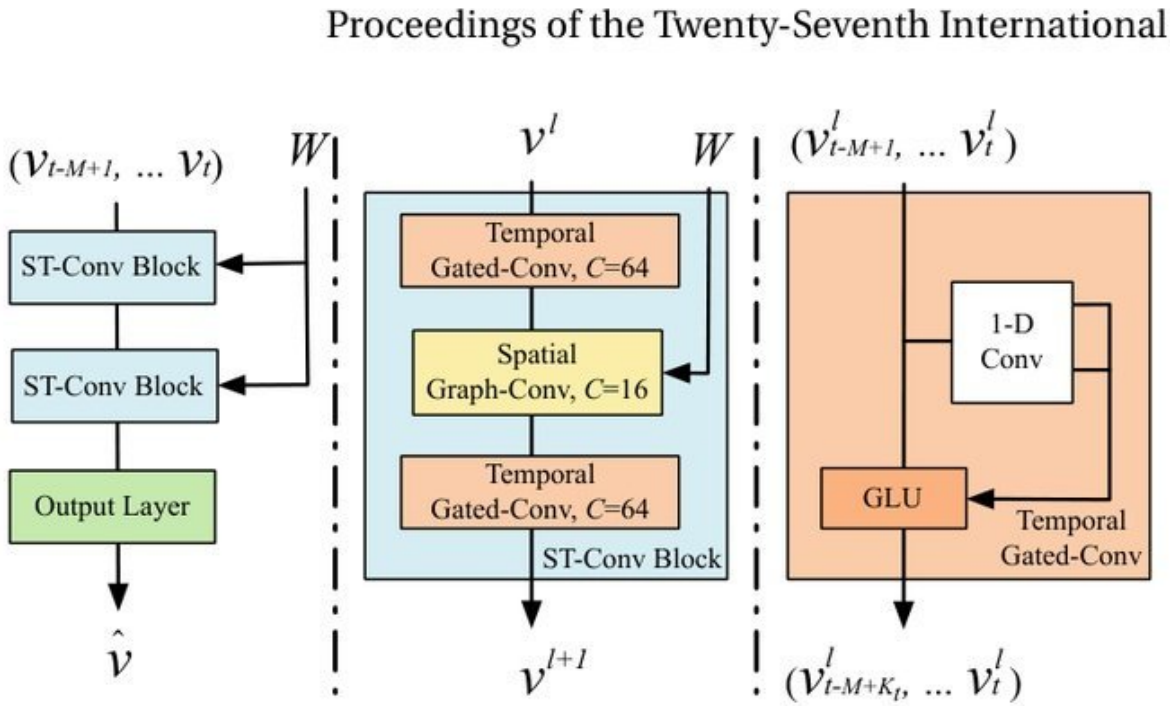
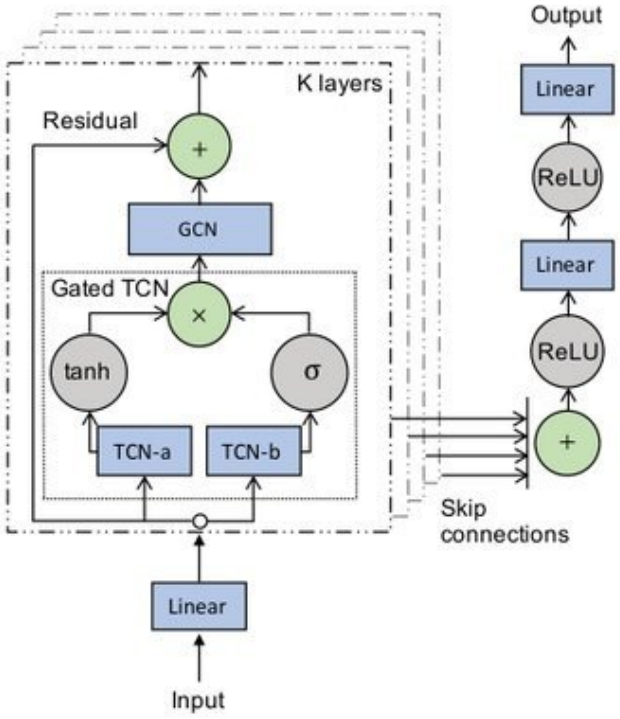


Figure 2: Architecture of spatio-temporal graph convolutional net-

图5-1　STGCN原论文的时空图卷积网络架构：多个ST-Conv Block后接输出层。来源：Yu等，IJCAI 2018，Figure 2 [1]。项目借用其中“显式图上的空间传播”思想，没有照搬完整时间卷积结构。



gure 3: The framework of Graph WaveNet. It consists of K

图5-2　Graph WaveNet原论文整体架构。来源：Wu等，IJCAI 2019，Figure 3 [2]。项目只借用节点嵌入生成自适应邻接的机制，没有复现其完整扩张因果卷积堆栈。

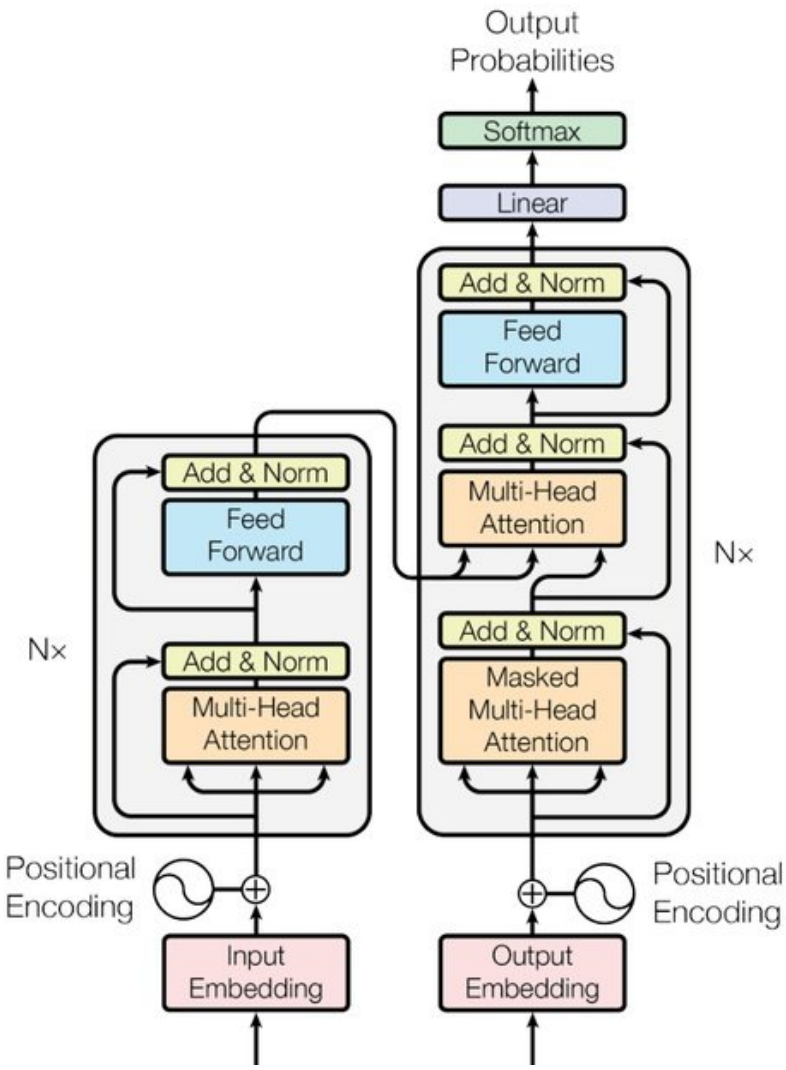


图5-3　Transformer原论文encoder-decoder架构。来源：Vaswani等，NeurIPS 2017，Figure 1 [3]。项目保留多头自注意力、残差、LayerNorm和FFN，将其用于每个节点内部的48步时间序列。

```
节点独立的时间多头自注意力
        ↓  残差 + LayerNorm
预定义空间图 DenseGCN + 自适应邻接传播
        ↓  相加 + ReLU + 残差 + LayerNorm
前馈网络 FFN
        ↓  残差 + LayerNorm
```

时间路径把每个节点的48个历史半小时步作为序列，使用2层、4头、`d_model=32` 的Transformer self-attention，并加入正弦位置编码。显式空间路径使用 `G_spatial` 的归一化邻接矩阵传播规则网格邻居信息。自适应路径学习两个节点嵌入矩阵 `E1`、`E2`：

$$A_{adaptive} = \mathrm{softmax}(\mathrm{ReLU}(E1 \times E2^{\top}))$$

在每个时间步，预定义图输出和自适应图输出相加。前者缩小搜索空间、提供稳定局部先验；后者补充远距离或无法由固定拓扑表达的关系。与Graph WaveNet不同，本模型没有使用其完整的扩张因果卷积堆栈；与STGCN不同，时间卷积被Transformer注意力替换。



图5-4　项目版AGFormer的数据输入、门控上下文、时间注意力、显式空间图、自适应图与线性残差路径。该图是项目实现示意，不是外部论文原图。

5.2 门控上下文融合

流量、时间日历和静态节点特征的统计性质不同，直接拼接或相加可能使弱上下文淹没主信号。门控版本先分别投影流量与上下文，再由当前流量状态决定上下文注入强度：

```
h_flow = Linear(flow)
context = Merge(TimeProjection, StaticProjection)
gate = sigmoid(Linear([h_flow, context]))
h = h_flow + gate × context
```

这种结构的直觉是，同一个节假日或商业区属性在不同流量状态下影响不同：模型无需在每个时间步强制使用相同强度的静态信息。消融结果中，AGFormer Time+Static三seed平均MAE为16.9376，门控上下文seed42达到16.5350，成为加入线性残差之前的最佳单模型。

5.3 Spacetimeformer 原版式对齐

Spacetimeformer把变量—时间对作为token，可用注意力直接学习全局时空联系，理论表达能力强于固定图模型。然而本项目有1,024个节点和48个上下文步，完整上下文达到49,152个token，标准二次注意力不可直接使用。实现过程因此分为多次对齐：

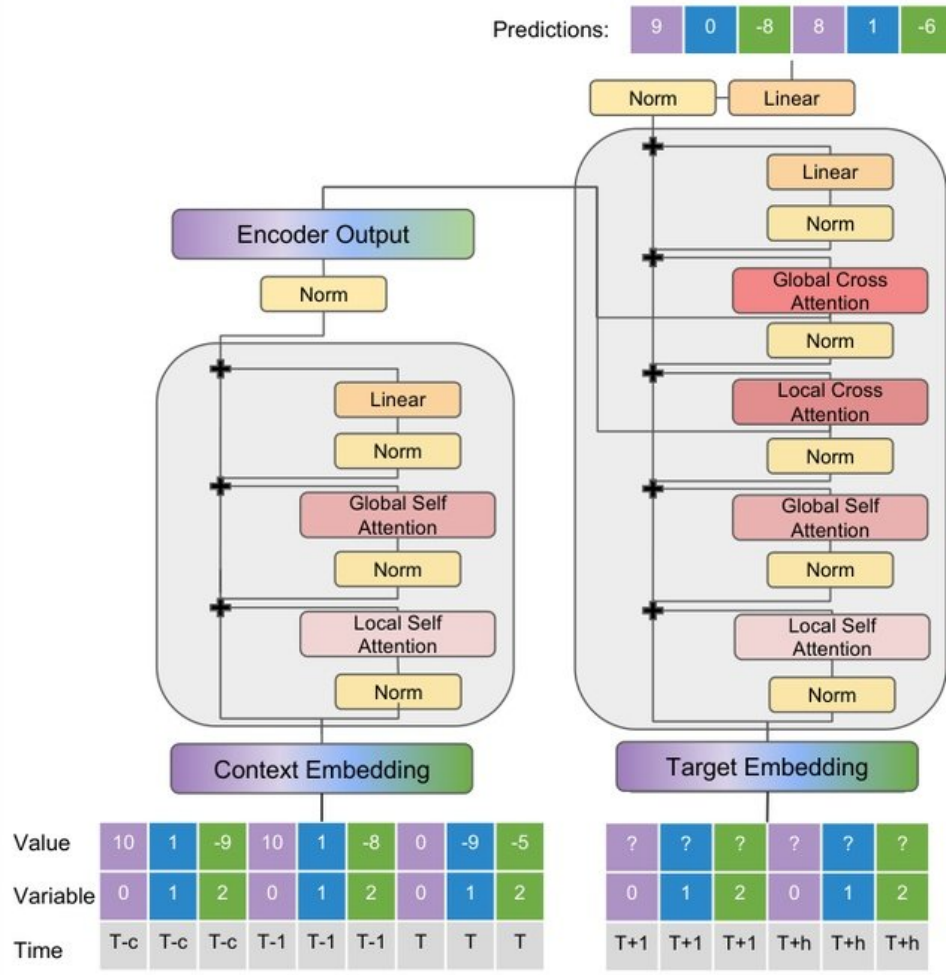


Figure 3: The Spacetimeformer architecture for joint s

图5-5　Spacetimeformer原论文的联合时空预测架构。来源：Grigsby等，arXiv:2109.12218，Figure 3 [4]。项目对齐value/time、given/missing、context/target token及local/global attention，但受49,152个上下文token限制仍需近似全局注意力。

1. 修复真实时间戳、gap-aware窗口和33维静态特征；
2. 将模型参数量匹配AGFormer，排除“模型太小”这一解释；
3. 引入local temporal attention和linear global spatiotemporal attention；
4. 分离value embedding与time embedding，增加given/missing embedding；
5. 增加encoder context token、decoder target token和更完整cross-attention；
6. 分别测试future time context、linear output和gated context。

实验显示，轻量realtime context版本MAE为17.9967；参数扩大后反而变为18.6715，说明容量不是主要瓶颈。更接近原论文的版本中，关闭future time context使MAE从18.4433改善到18.2950，表明解码侧未来时间信息在当前数据与目标中可能形成噪声。加入linear output后MAE大幅改善到17.0688，但仍未超过AGFormer。

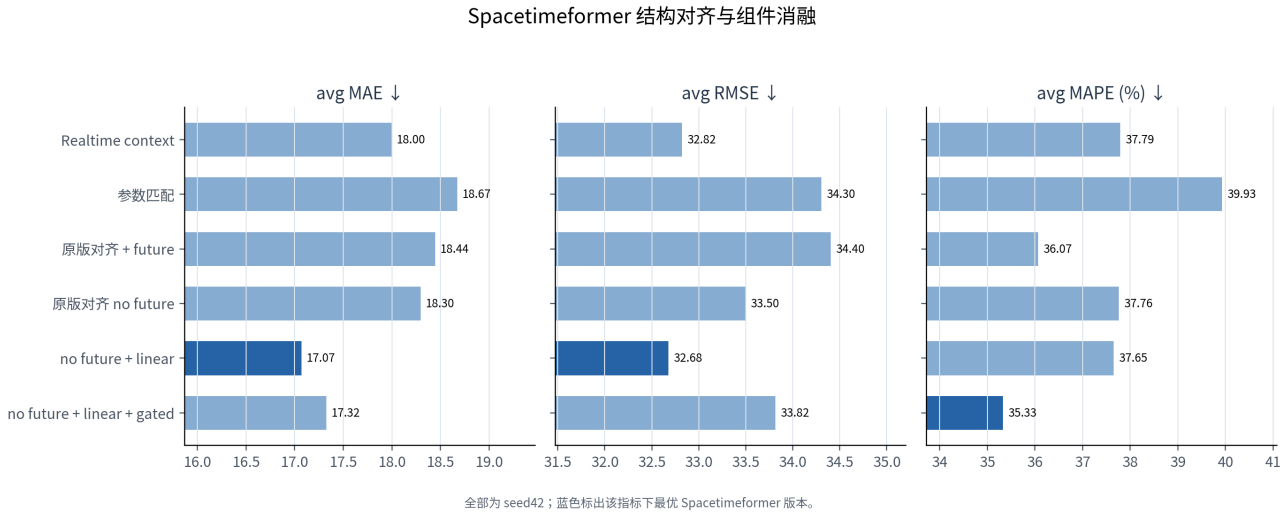


图5-6　Spacetimeformer从参数匹配到原版式embedding、future context、linear和gate的主要消融结果。

该结果并不意味着Spacetimeformer普遍弱于图模型，而是说明在当前规则网格、样本规模和计算预算下，显式空间先验具有更高样本效率；把所有关系重新交给token注意力学习，既增加优化难度，也需要近似注意力。负结果的价值在于排除了“只要更大、更接近原版就一定更好”的假设，并发现了可迁移的线性输出路径。

5.4 外生特征、周期滞后与多图消融

Week 4按“单因素变化—同窗口对照”的原则测试了多种增强方案：

实验	avg MAE	主要结论
完整Calendar context	17.8542	调休日历更正确，但未改善MAE
Calendar + Weather	17.8316	相对日历仅小幅变化，缺乏稳定收益
Multi-graph AGFormer	16.9569	低于多数模型但未超过单空间图门控版本
lag_48 / lag_336 / delta	17.9614	周期特征减少有效窗口，严格匹配对照下无收益

周期滞后实验由于 `lag_336` 要求更长历史，测试窗口从4,022降为3,433。因此项目另在相同3,433个窗口上评估原单图模型，基线MAE为16.2443，避免把窗口变化误认为模型变化。多图checkpoint的全局权重为flow　92.18%、spatial 7.37%、POI　0.42%、transit　0.02%，说明全局softmax无法按节点、时段或层动态选择关系，流量图又与强历史输入高度重复。

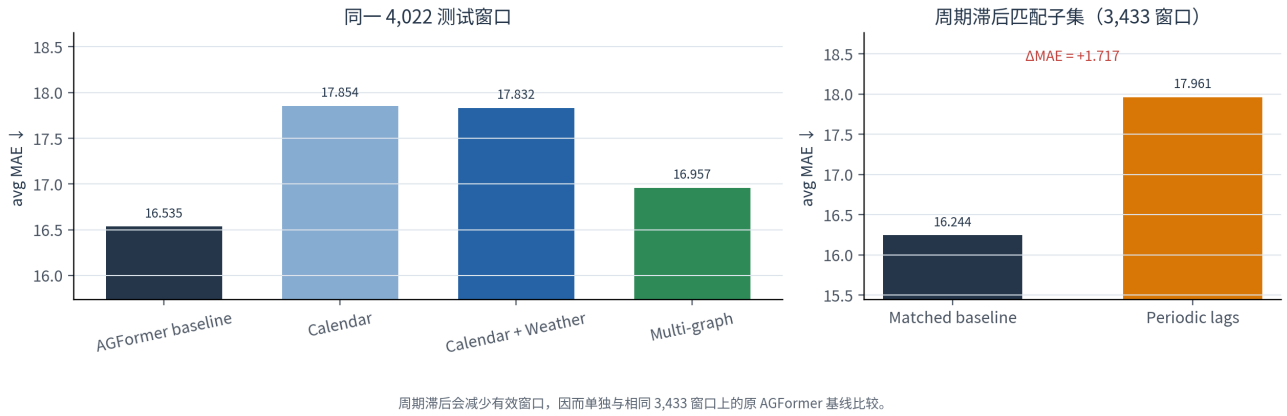


图5-7　日历、天气、多图和周期滞后方案的平均MAE；周期滞后采用独立的同窗口对照。

5.5 Linear residual head

Spacetimeformer实验显示，历史流量中存在非常强的线性自回归成分。项目将过去48步inflow直接通过线性层映射为未来48步，并与非线性主干相加：

```
prediction = nonlinear_AGFormer(history, graph, context)
           + Linear(history_inflow)
```

线性分支负责稳定的日内惯性和趋势，AGFormer集中学习图传播、时间交互和非线性偏差。相同seed42下，平均MAE从16.5350降到16.1132，MAPE从37.35降到36.91，RMSE由30.1288轻微升至30.3198。这说明平均绝对误差改善并不等于尾部大误差同时下降，最终选型需要同时保留RMSE审计。

四个随机种子的AGFormer+linear结果为：

seed	MAE	RMSE	MAPE
42	16.1132	30.3198	36.91
7	16.9079	31.9627	39.75
21	16.4172	31.2766	36.51
123	16.5463	31.1309	38.10

MAE均值为 `16.4961 ± 0.2850`，支持linear head的收益并非单seed偶然。将四个模型在逐样本预测层取算术平均后，完整24小时MAE进一步降为15.9030。ensemble不是把四个指标求平均，而是先平均四组预测，再与真实值计算一次指标，因而能够抵消部分随机初始化方差。

5.6 最终预测结果与模型选择

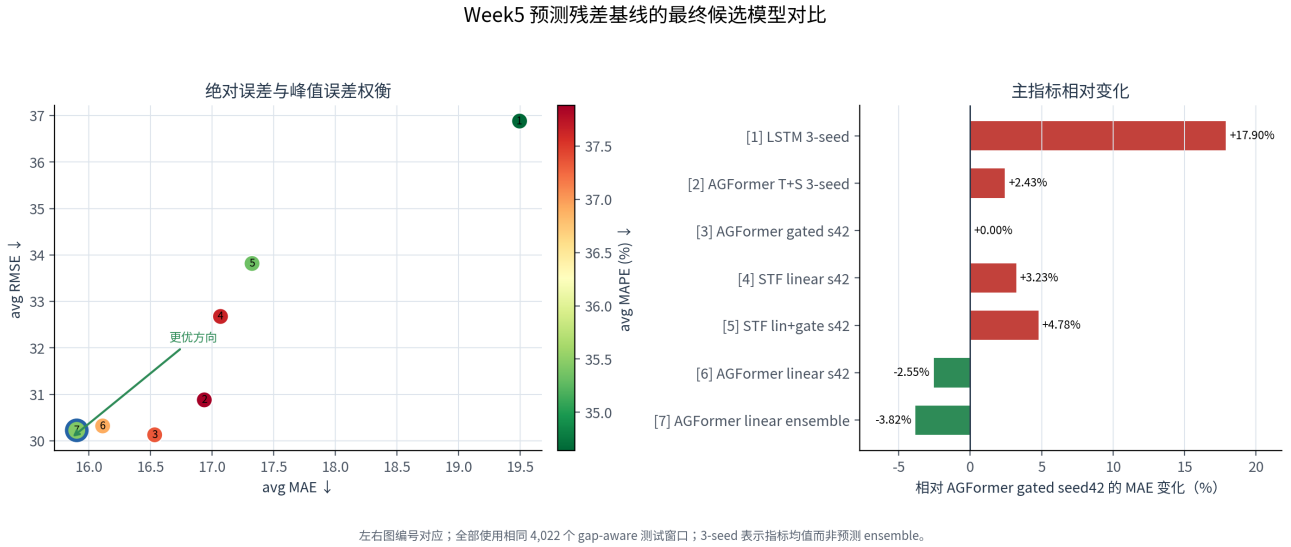


图5-8　相同4,022个严格测试窗口上的最终候选模型对比。

模型	参数口径	avg MAE	avg RMSE	avg MAPE
LSTM gap-aware 3-seed均值	0.054M	19.4941	36.8806	34.64
AGFormer Time+Static 3-seed均值	0.050M	16.9376	30.8805	37.88
AGFormer gated seed42	0.050M	16.5350	30.1288	37.35
Spacetimeformer no-future + linear	0.091M	17.0688	32.6759	37.65
AGFormer gated + linear seed42	0.052M	16.1132	30.3198	36.91
AGFormer gated + linear 4-seed ensemble	4×0.052M	15.9030	30.2250	35.44

最终选择ensemble作为离线异常残差和24小时预测主模型，因为MAE最低、MAPE优于原AGFormer，且正常时段残差底噪更低。实时资源受限时采用seed42单模型作为降级方案，只需一次forward，MAE仅比ensemble高0.2102。原gated seed42保留为最低RMSE审计参考。该角色划分比宣称某个模型“所有指标绝对最优”更符合工程实际。

6. 三路异常检测、事件融合与分类

6.1 弱监督任务定义

项目样本不包含权威异常事件真值，因此不能直接进行标准监督分类。Week 5采用统计规则生成弱标签，作为固定评估锚点，并保留两级口径。Level-A要求同一时间步至少12个网格的inflow z-score大于3；Level-B在此基础上还要求至少25个网格的outflow z-score大于3，代表更严格、更稀疏的同步流入流出异常。outflow统计量独立在训练集拟合，避免用inflow离散程度代替outflow。

弱标签的意义是让三类方法在同一参考下比较，不是把规则生成结果包装成人工真值。尤其统计分支与弱标签都依赖时槽z-score，存在同源性，因此其召回率为1具有结构性优势。报告始终将Precision、Recall和F1解释为“与弱标签的一致性”，而不是现实事件识别准确率。

6.2 统计检测：3σ与IQR

统计分支在训练集上为每个“日内时槽×网格”计算均值、标准差、Q1、Q3与IQR：

```
z = (x - mean[slot,node]) / std[slot,node]
IQR = Q3 - Q1
normal range = [Q1 - 1.5×IQR, Q3 + 1.5×IQR]
```

3σ对均值附近的标准化偏离敏感，IQR对偏态和极端历史值更稳健；统计分数取二者较强证据，并区分high、low和bidirectional方向。按网格与时槽拟合的原因是，商业区晚高峰与郊区夜间的“正常范围”不同。该方法覆盖率高、解释直接，但统计检测正例率达到41.77%，单独使用会产生大量候选。

6.3 重构检测：VAE与Transformer AE

VAE输入单个时刻的1,024维inflow网格，将其压缩为概率潜变量后重构空间分布；Transformer AE输入长度12的序列，即连续6小时，对每个时间步进行重构。前者关注单时刻整体空间形态，后者关注演化过程是否符合正常模式。

两种自编码器都只用weak-normal样本训练。VAE只接受Level-B弱标签为0的时间步；Transformer AE要求12步窗口中所有时间步都不是Level-B异常。训练集15,738个时间步中有199个Level-B弱正例，最终VAE使用15,539个向量，Transformer AE形成14,933个正常窗口。这样可以降低模型“学会重构明显异常”的风险，但weak-normal仍可能包含漏标异常，因此不能称为严格正常数据。

6.4 预测误差检测

第三条分支使用Week 4最终四seed AGFormer ensemble：

```
prediction_residual = |observed_inflow - predicted_inflow|
```

实时异常采用h1即未来30分钟预测，因为它精度最高且符合观测到达后的即时比较。预测残差能够识别“绝对流量不高但与历史、时间和空间关系不一致”的变化；同时它也可能把模型本身的预测失败当成异常，因此不适合作为唯一依据。在验证口径下该分支覆盖较低，最终融合权重为0.10，主要发挥补充作用。

6.5 分数校准与加权软投票

三类原始分数量纲不同，先按各自验证阈值映射到0–1：

```
confidence = clip(score / (2 × threshold), 0, 1)
```

原始阈值对应0.5置信度。这里的confidence只是可比较的异常强度，并非经过概率校准的“异常发生概率”。融合公式为：

```
fusion_score = 0.70 × statistical_confidence
             + 0.20 × reconstruction_confidence
             + 0.10 × prediction_confidence
```

最终阈值0.56、最少异常网格数6均在验证集选择后固定。另一个无精度约束方案使用0.60/0.20/0.20和阈值0.51，在测试Level-A上F1更高但输出207个事件；最终高精度方案输出131个事件，Level-B F1更高、人工核验负担更小，更适合交付。

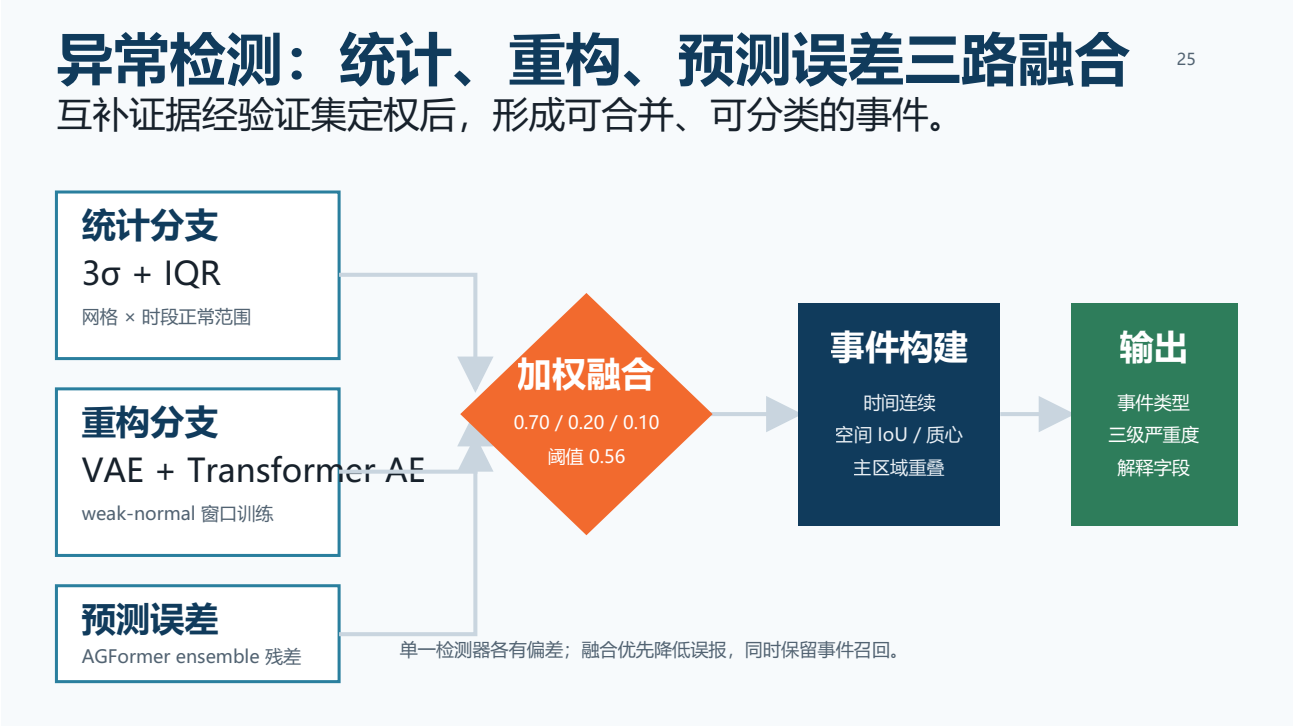


图6-1　统计、重构和预测误差三路证据经过验证集定权、阈值判断、空间聚类与事件分类的完整流程。

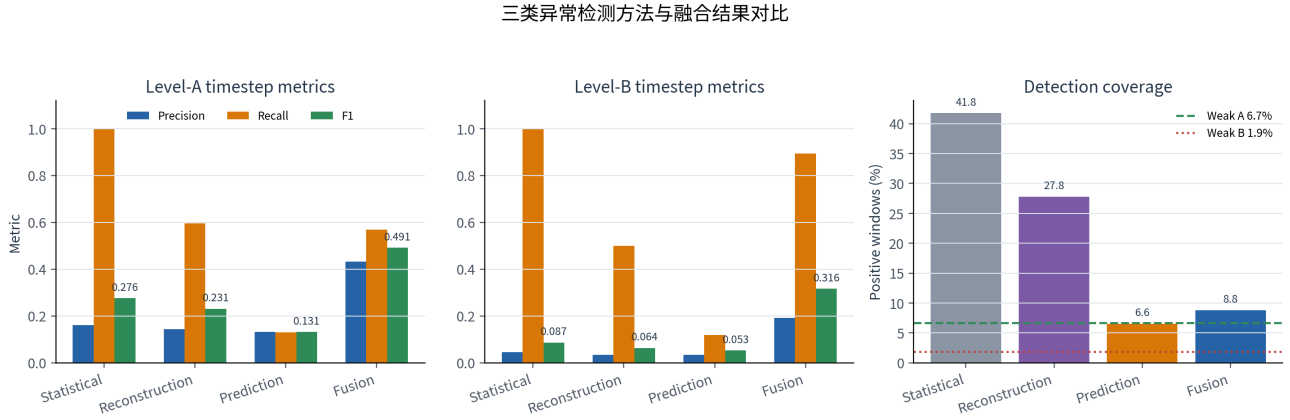


图6-2　三类单方法与最终融合在两级弱标签上的timestep指标和检测覆盖率。

6.6 从异常网格到时空事件

每个时间步先按八邻域提取连通异常簇。两个相邻时间步只有在时间连续，并且空间IoU不低于0.05或异常掩码质心距离不超过4个网格时，才合并为同一事件：

```
IoU = |mask_t ∩ mask_t+1| / |mask_t ∪ mask_t+1|
```

IoU适合区域稳定重叠的事件，质心距离允许人群或拥堵区域缓慢移动。非连续30分钟缺口强制断开。事件级评估采用一对一最大基数匹配，避免一个预测事件重复命中多个参考事件。

最终双向融合产生131个候选事件。Level-A下timestep　　Precision/Recall/F1为0.4322/0.5688/0.4912；事件级为0.4580/0.5085/0.4819，对应118个参考事件、131个预测事件和60个一对一匹配。Level-B事件召回为0.7931，但Precision较低，因为参考事件更少。事件级F1不一定高于timestep　F1：事件被拆成多个片段或被错误合并时，会额外产生FP或FN；其价值在于更接近实际处置语义。

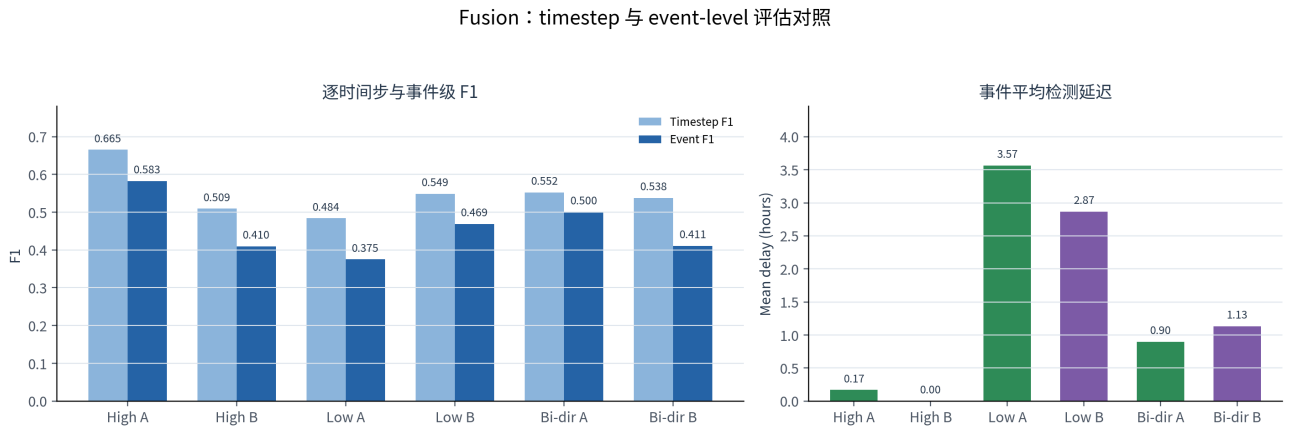


图6-3　同一融合输出在逐时间步和事件级口径下的F1与检测延迟。

6.7 事件分类与解释字段

事件类型由规则特征推断：大型集会强调较大范围、持续性和相对均衡的流入流出；交通拥堵强调带状形态、道路密度和较长持续时间；突发事件强调短时、小范围、多簇或不稳定形态。使用的主要特征包括　　`aspect_ratio`、`road_density`、`in_out_imbalance`、`duration_trend` 和 `cluster_count`。最终规则输出14个大型集会、6个交通拥堵和111个突发事件，但没有类别真值，不能将这一分布解释为分类准确率。

每个事件同时输出 statistical/reconstruction/prediction score、dominant method、top cells、最大z-score、最大重构误差、最大预测残差、道路密度、流入流出不平衡和趋势斜率。119/131个事件由统计分支主导，说明系统本质上仍是统计规则主导、深度方法补充的融合基线。

为支持人工核验，系统分层抽取50个事件：20个最高置信、15个阈值附近边界事件、15个“弱标签未命中”的候选。后者只能称为weak-label false-positive candidate，不能在未人工查看前称为真实假阳性。人工字段预留 `manual_is_real_anomaly`、`manual_event_class` 和 `manual_notes`，但当前未完成权威标注。

7. 系统实现：端到端流水线、API、Web与预警



图7-1　Batch/realtime流水线、FastAPI查询服务、地图可视化与三级预警之间的系统关系。右侧界面截图来自项目原型。

7.1 Batch与realtime微批流水线

Week　6将数据校验、特征产物、模型推理、异常检测、事件构建和预警映射封装为统一pipeline。Batch模式适合离线重跑完整测试段或复用Week 5结果生成历史预警；realtime模式读取最新N个有效窗口，加载固定checkpoint和校准阈值，执行微批预测与异常检测。当前“实时”是离线数据上的滚动模拟，并未连接真实消息队列，报告不会将其描述为生产在线流。

预处理与特征工程默认只校验已生成artifact，只有显式配置才从原始数据重建。重构模型在realtime中强制`inference_only=true`：checkpoint缺失或配置哈希、数据路径、切分、缩放器、标签规则不匹配时直接失败，不会在服务进程中偷偷训练。最新同一forecast origin的48步预测保存为独立`forecast_24h.npz`，避免把48个不同起点的h1结果错误拼成24小时预测动画。

7.2 FastAPI服务

FastAPI与GPU推理解耦，只读取pipeline原子发布的NPZ、CSV和JSON快照。这样HTTP　worker不加载四个AGFormer和两个自编码器，查询延迟、显存和故障边界更可控。主要接口包括：

方法	路径	功能
GET	`/api/v1/status`	服务与artifact就绪状态
GET	`/api/v1/heatmap`	指定时间、区域的观测或h1预测热力图
GET/POST	`/api/v1/predictions`、`/predict`	同一预测起点的未来24小时序列
POST	`/api/v1/anomaly/detect`	对已有三方法融合分数执行时间片判定
GET	`/api/v1/anomalies`	历史或实时事件筛选与分页
GET	`/api/v1/anomalies/{event_id}`	单事件详情和解释字段
GET	`/api/v1/alerts`	按三级预警查询
GET	`/api/v1/statistics`	事件类型、等级和时间统计

接口支持grid ID、行列范围、时间、类型、等级和最低分数过滤；缺失必要artifact时业务接口返回503，status仍可返回200和degraded状态。当前API无身份认证，正式部署只能绑定本机/内网，或置于带TLS、认证和VPN的反向代理之后。

7.3 Streamlit地图与交互

Web端以地图为主组件，提供当前观测与预测热力图、同一origin的未来48帧动画、异常事件marker与详情、历史事件检索、类型/等级/时间统计以及自动刷新。重要预警触发横幅和弹窗，紧急预警额外播放声音；浏览器会话记录已确认event ID，避免每次刷新重复打扰。

地图背景复用项目数据收集阶段的Landsat影像并重投影到WGS84，同时叠加环路参照。由于原始流量网格缺少权威bbox，项目采用独立展示坐标校准：保持32×32方向和尺度不变，仅对覆盖层做南北/东西平移。训练用`grid_meta`、node ID、静态特征、图结构、预测与异常结果均未修改，因此地图校准不影响Week 4/5指标；它也不能证明绝对地理定位已完全正确。

7.4 三级预警

Week 5保留研究型severity 1–4，Week 6增加产品层映射而不覆盖原字段：severity 1–2为一般，只进入列表和地图；severity 3为重要，触发横幅、地图高亮和弹窗；severity 4为紧急，增加红色强提醒与声音。131个历史事件映射为110个一般、15个重要和6个紧急，只有21个事件触发弹窗，降低预警疲劳。

这种分层把“检测强度”与“界面行为”解耦。后续若人工核验表明某类误报较高，可以修改产品预警映射而不破坏Week 5原始事件和评估复现性。

8. 实验结果、可解释性分析与性能优化

8.1 最终预测精度与误差结构

最终四seed ensemble在4,022个严格测试窗口上的结果如下：

范围	时间跨度	MAE	RMSE	MAPE
h1	0.5小时	11.3019	19.8621	23.49
h3	1.5小时累计	12.6473	22.9856	26.18
h6	3小时累计	13.4194	24.7530	28.28
h12	6小时累计	14.1068	26.2676	30.66
avg	24小时	15.9030	30.2250	35.44

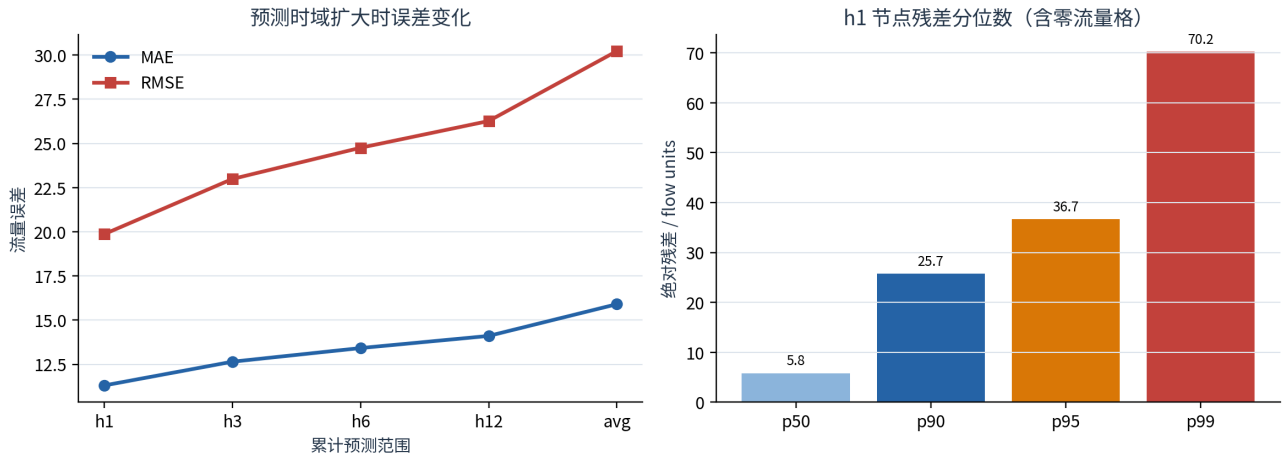


图8-1　预测时域扩大时误差上升，h1节点残差呈明显长尾。

空间上，1,024个网格h1 MAE中位数为9.4145，P90为21.3621，最困难grid 157达到43.8480。时间上16:00 MAE为24.4416，显著高于多数时槽。该异质性说明全局平均不能替代节点与时段审计，未来可对高误差区域建立局部校准器或分层阈值。

8.2 时间注意力与空间自适应图

注意力分析覆盖四个checkpoint、测试集首中末四个日期和两层AGFormer。聚合后平均时间注意力归一化熵为0.9956，最近3小时注意力质量占0.1223。第一层相对关注9.5–13小时前，第二层同时关注最近时刻和8.5–9.5小时前。高熵表示跨模型和样本平均后较分散，不能推断每个样本都没有关键lag，也不能把attention直接解释为因果贡献。

自适应邻接平均行熵为0.7261，top-k权重平均集中度为0.2238，说明节点嵌入学到了非均匀关系。但该分析只解释非线性分支的learned graph，不覆盖预定义spatial GCN和并行linear residual head，因此不是完整空间贡献分解。

8.3 TreeSHAP代理特征重要性

为解释完整四seed ensemble的h1行为，项目使用时间留出的ExtraTrees代理模型，再用TreeSHAP分解。代理模型R^2为0.9926、MAE为4.4381 flow units，SHAP平均加法误差约 `4.13×10^-6`。历史inflow与outflow的重要性占比分别49.80%和47.63%，合计97.43%；时间日历占2.33%，静态各组全局占比较小。

排名靠前的特征集中在最近1–4个半小时步以及lag 46–48，说明短期惯性与接近前一日边界的信息都重要。静态特征占比小不等于无用：代理输入压缩、门控交互、节点条件化和全局聚合都会稀释单组mean |SHAP|。TreeSHAP解释的是高拟合行为代理，不是直接对神经网络求梯度，必须与代理质量一起阅读。

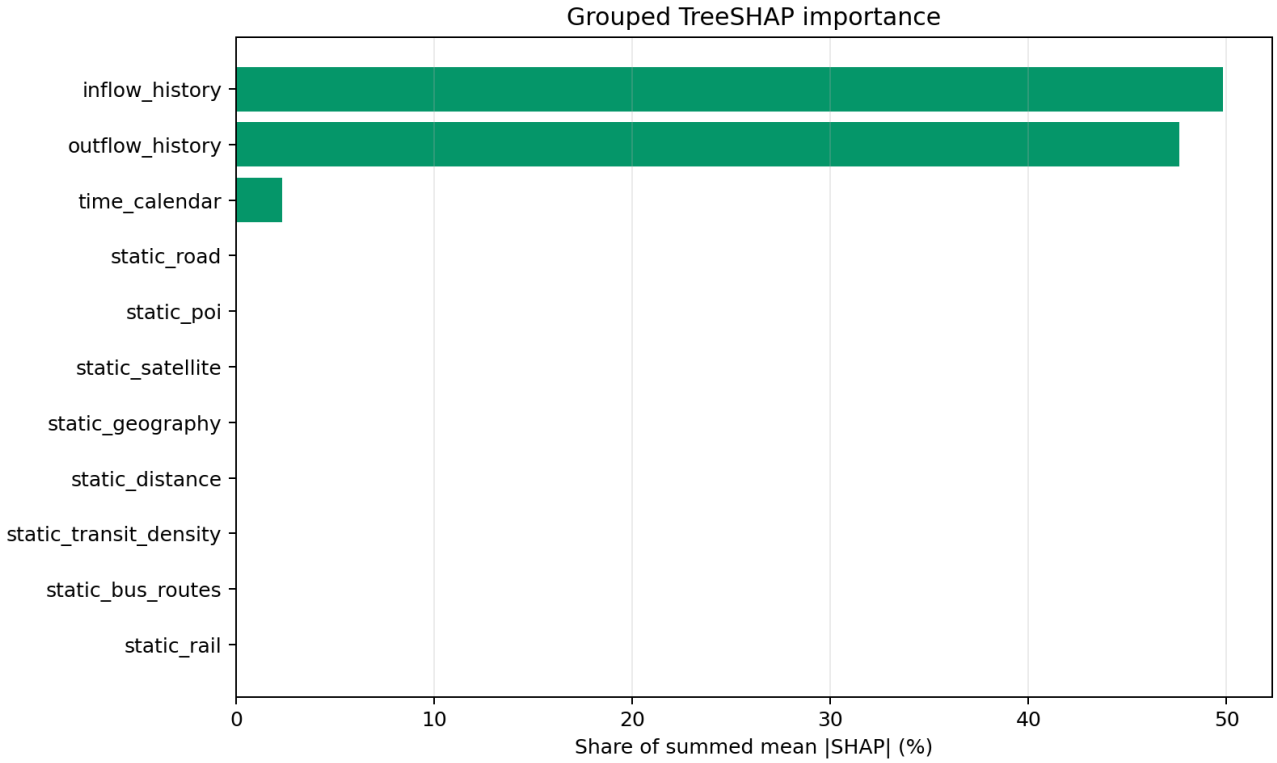


图8-2 完整ensemble行为代理的历史流量、日历和静态特征组mean |SHAP|占比。

8.4 异常上下文证据

131个融合事件中，46个匹配极端温度候选证据，17个匹配强风，13个发生在法定节假日，3个发生在调休工作日，3个表现为周末模式，49个没有外部上下文匹配。天气时间覆盖率为100%，但未配置可验证的新闻或活动表，因此新闻匹配数为0。

这些输出只能称为“候选上下文证据”：天气与事件同现不证明天气导致事件，规则 `event_type` 也只是形态标签。系统保留“未知”比强行为每个异常生成故事更可靠。

8.5 系统性能优化

Week 7使用测试集末尾24个有效窗口固定基准，比较相同模型、输出和异常规则。主要优化包括：让h1和Web forecast共享一次完整序列推理；按数据SHA-256、训练长度、时区和规则缓存时槽统计量；普通预测关闭未使用attention weight物化；小微批将DataLoader worker从2改为0；API对事件时间转换和坐标合并建立mtime-aware派生缓存。

方案	流水线秒数	峰值RSS MiB	CUDA峰值MiB
baseline FP32	6.416	3881.5	826.2
optimized cold FP32	6.106	2793.2	703.7
optimized warm FP32	4.613	1791.2	703.7
optimized warm FP16	4.596	1894.4	419.7

正式候选为暖启动FP32：端到端1.39倍加速，进程树RSS汇总下降53.9%，CUDA峰值下降14.8%。batch扫描中8的中位模型延迟最低；batch 24显存升至约2,074MiB且速度反而变慢。FP16数值门槛通过但速度仅0.9945倍，未达到1.05倍部署门槛；动态INT8只在CPU单模型微基准中约1.305倍，未覆盖生产CUDA ensemble，因此不部署。

API优化后，历史事件和统计端点分别约1.59倍和1.69倍；完整热力图与48×1024 forecast JSON略慢，瓶颈转向Python对象构建、JSON序列化和压缩，不能宣称所有接口全面加速。

8.6 Optuna超参数优化方案

受时间和GPU预算限制，Week 7完成了可执行方案与代码，但没有运行Optuna，因此不报告虚构最优参数。方案冻结数据、切分、9维动态输入、33维静态特征、single spatial graph、gated fusion、linear head、Huber loss和指标规则，只搜索学习率、batch、`d_model`、head数、FFN倍率、层数、dropout、weight decay与adaptive embedding维度。

计划使用TPE、30 trials、18小时软墙钟、单GPU串行、MedianPruner、SQLite恢复和协议指纹。搜索objective只构建训练/验证数据；Top-5进行同预算全量验证训练，至少相对同轮incumbent改善0.5%才进入四seed复验；只有通过稳定性门槛后，显式 `--run-final-test` 才访问一次4,022窗口测试集。这种门禁避免在自动搜索中反复查看测试集造成选择偏差。

9. 综合结果、项目亮点与技术难点

9.1 从研究原型到可运行系统

五个月工作的核心结果不只是一个误差数字，而是一条可追溯的完整链路：原始半小时网格流量经过时间连续性检查、训练集拟合的归一化、动态与静态特征构建和图结构映射，进入多模型预测；预测残差再与统计检测和重构检测融合，形成带等级、类型和解释字段的异常事件；最终通过批处理、实时微批、REST API和地图界面提供服务。Week 7的固定基准进一步验证了精度、延迟、内存和可解释性输出。

最终预测候选为四seed AGFormer+linear ensemble，24小时平均MAE为15.9030，h1 MAE为11.3019。异常模块在缺少人工真值的条件下没有把弱标签F1包装成真实业务准确率，而是同时输出high/low/bidirectional三种方向口径、timestep与event-level评估、50事件人工核验表以及证据字段。系统层保留了研究字段与产品预警字段之间的转换，因而后续可以独立更新阈值、界面行为和人工处置规则。

9.2 主要亮点

1. 严格的时间防泄漏设计。 切分后再切窗、窗口内连续性校验、训练集拟合scaler、Optuna验证/测试门禁，贯穿预测、异常检测和调参方案。
2. 动态图与静态上下文联合建模。 固定空间图编码邻域传播，自适应邻接学习数据驱动的非局部关系，33维静态节点特征和时间上下文通过门控进入AGFormer。
3. 以消融而非模型名称驱动选型。 对日历、天气、多图、周期滞后、future-time context、原版式Spacetimeformer组件和linear residual逐项验证。复杂模块无增益时保留负结果，并回到更可靠的候选。
4. 三路异常融合和事件化表达。 统计、重构和预测残差的分数先校准再软投票；空间簇通过IoU或质心距离与时间连续性合并，避免把孤立网格报警直接暴露给业务端。
5. 研究与工程评价闭环。 同一最终候选同时接受多seed精度复验、注意力和SHAP代理解释、流水线时延/RSS/CUDA显存测试、API缓存与部署边界审计。

9.3 关键技术难点及处理

第一，原始时间轴包含多段间断。若只按数组下标切窗，模型会把跨缺口样本当作连续序列。项目将连续性检查纳入窗口生成，并将有效样本数和切分口径写入结果，从源头避免隐性泄漏。

第二，节点有流量、日历、天气、POI和交通设施等异质信息，量纲、时变性和可信度不同。项目没有一次性堆叠全部特征，而是先形成候选特征，再通过训练时可用性检查和消融筛选；全序列统计产生的8维静态流量画像被移出最终输入，以免引入未来信息。

第三，复杂Transformer不必然优于较小模型。Spacetimeformer在local/global attention、encoder-decoder embedding和cross-attention逐步对齐后仍未胜出，说明本任务的数据量、网格规模、长预测跨度和优化预算共同限制了优势发挥。并行linear head反而改善了AGFormer，因为它为强短期自回归成分提供了低方差路径，而非线性分支可集中学习残差和空间交互。

第四，异常检测没有人工真值。项目使用弱标签完成相对比较，同时明确其循环性；通过事件级评估、方向拆分、人工抽样表、三方法贡献和外部上下文候选证据降低误读风险，但不把这些结果等同于真实线上召回率。

第五，原始网格缺少权威地理bbox。地图覆盖层只做展示坐标校准，训练节点、静态特征和图结构保持不变，并在部署文档中明确绝对位置仍需权威元数据确认，避免为了视觉对齐修改实验数据。

10. 评估边界、局限性与改进方向

预测指标来自固定历史测试集，能够比较同口径模型，但不能替代跨城市、跨季节和分布漂移测试。四seed ensemble改善了稳定性，却增加了推理成本；当前性能优化已缓解该问题，进一步可研究蒸馏、共享backbone或按不确定度启用ensemble。模型对高峰时段和少数高误差节点仍不均衡，可引入节点分层损失、分位数预测和校准区间。

异常评估的主要限制是缺少人工标注。弱标签由同一流量序列构造，检测器若接近标签规则会天然占优；50事件核验表只是抽样工具，尚未形成正式标注集。下一阶段应由业务专家采用双人复核和冲突仲裁建立事件真值，报告event precision、recall、检测延迟、误报间隔以及不同预警等级的处置成本，并在验证集重新学习融合权重和阈值。

外部证据目前以天气和日历为主，新闻/活动证据为空，因此“异常类型”应理解为基于时空形态的候选类型。若能接入经过授权的道路状态、活动和事件信息，可建立可审计的证据链接，并区分相关性、可能原因和已确认原因。地图也需要权威网格边界和坐标参考才能支持线下处置。

系统原型尚未覆盖认证、权限、限流、消息队列、持久化事件库、在线漂移监控和高可用部署。正式上线需要在内网或TLS反向代理后运行，增加模型/数据版本注册、回滚、审计日志、Prometheus指标和灰度发布。Optuna代码已经落实但未执行；未来应在固定预算下先做训练/验证搜索，再进行多seed复验和一次性测试，不能用测试集指导trial选择。

11. 总结与展望

本项目围绕网约车安全场景下的城市人流感知，完成了“数据治理—特征与图构建—预测模型比较—异常融合—API与可视化—解释和性能审计”的端到端闭环。实践表明，稳定提升更多来自时间口径修复、信息防泄漏、严格消融和与数据规律匹配的结构，而不是简单扩大Transformer。最终AGFormer+linear多seed ensemble成为Week 4预测候选，三路融合事件检测衔接Week 5，Week 6–7则将研究结果变为可查询、可解释、可测量的系统原型。

后续工作按优先级包括：建立人工事件真值和处置反馈闭环；补齐权威地理元数据及经过授权的外部事件证据；执行受控Optuna搜索与跨时段复验；研究概率预测、异常不确定度和漂移检测；通过蒸馏、缓存、批处理与异步事件存储提高线上效率。最终目标不是只追求离线MAE或弱标签F1，而是形成可复现、可解释、可运营且能够持续校准的人流安全决策支持能力。

参考文献

[1] Yu, B., Yin, H., & Zhu, Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting. IJCAI, 2018.

[2] Wu, Z., Pan, S., Long, G., Jiang, J., & Zhang, C. Graph WaveNet for Deep Spatial-Temporal Graph Modeling. IJCAI, 2019.

[3] Vaswani, A., et al. Attention Is All You Need. NeurIPS, 2017.

[4] Grigsby, J., Wang, Z., Nguyen, N., & Qi, Y. Long-Range Transformers for Dynamic Spatiotemporal Forecasting. arXiv:2109.12218, 2021.

[5] Kingma, D. P., & Welling, M. Auto-Encoding Variational Bayes. ICLR, 2014.

[6] Lundberg, S. M., & Lee, S.-I. A Unified Approach to Interpreting Model Predictions. NeurIPS, 2017.

[7] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. Optuna: A Next-generation Hyperparameter Optimization Framework. KDD, 2019.

附录：需求覆盖与主要交付物

学校要求部分	报告对应章节	主要证据
项目背景、需求分析	第1章	业务问题、功能与非功能需求
技术路线	第2章	端到端路线、20周安排
数据处理	第3章	连续性、切窗、特征、图构建
模型设计	第4–5章	基线、AGFormer、Spacetimeformer、消融与ensemble
系统实现	第6–7章	三路异常、流水线、API、Web、三级预警
实验结果	第5、6、8、9章	预测、异常、性能与综合结果
可解释性分析	第6.7、8.2–8.4节	方法贡献、attention、adaptive graph、SHAP、上下文证据
总结与展望	第10–11章	边界、局限、后续路线

主要工程与文档交付物包括：可配置训练与评估脚本、预测与异常checkpoint/result artifacts、Week 1–7报告、Week 6 API与部署指南、Week 7三类专项报告、可恢复Optuna方案、FastAPI服务、Streamlit地图界面和自动化测试。所有数字均来自现有固定实验输出；本报告未为补写内容重新训练模型，也未把尚未执行的优化计划写成实验结论。