

WEEK 2 · 数据预处理与特征工程

城市人流异常检测系统

第二周进度报告

基于多源时空数据融合的城市级人流异常检测与预警系统

报告日期

2026-06-17

阶段

Week 2 / 8

覆盖城市

北京 (BJ)
• 纽约
(NYC)

数据集

TaxiBJ •
TaxiNYC •
12数据源

41

维节点静态特征

4

类多模态图结构

13

个预处理脚本

3.7GB

原始+预处理数据

一、本周完成概览

Week 2 全部四项交付物已完成：数据预处理脚本 13 个、特征工程代码库（src/features/，16个公开符号）、预处理数据集（41维节点特征矩阵 + 4类多模态图，共 37 个文件）、数据质量分析报告。

13

个脚本

数据预处理 Python 脚本

4

个模块

特征工程可导入代码库

37

个文件

预处理产物（100 MB）

12

个来源

数据质量全覆盖分析

1.1 交付物清单

- ☑ 数据预处理 Python 脚本（scripts/ 目录，13 个脚本）
- ☑ 特征工程代码库（src/features/，4 个模块，16 个公开符号，完整可导入）
- ☑ 预处理数据集：北京 (1024, 41) + 纽约 (75, 41) 节点特征矩阵，NaN=0
- ☑ 预处理数据集：北京 + 纽约各 4 张多模态图（.pt 格式，PyTorch Geometric 兼容）
- ☑ 数据质量分析报告（覆盖全部 12 个数据来源）
- ☑ 特征工程技术报告（outputs/reports/feature_engineering_report.md）
- ☑ 量化 / TensorRT 加速预研报告
- ☑ 可视化界面设计文档

1.2 数据规模说明

分类	大小	说明
data/raw/	3.6 GB	Landsat-8 2.3GB、MTA GTFS 0.5GB、METR-LA 0.2GB、OSM 0.2GB、taxi 0.4GB 等
data/ processed/	100 MB	全部预处理产物（npz / csv / pt / npy，共 37 个文件）
合计	~3.7 GB	—

关于课题文档估计"约 20 GB"的说明：该估计基于原始出租车 GPS 轨迹数据（逐条行程记录）。本项目使用官方预聚合网格版本（TaxiBJ 32×32 / TaxiNYC 15×5 ），已将原始轨迹聚合为 inflow/outflow 计数，数据量远小于原始轨迹，但信息完整，不影响模型训练与评估。

二、数据预处理脚本

2.1 脚本清单 (scripts/ 目录)

脚本	功能	输出
<code>build_spatial_features.py</code>	路网密度 (5类) + 地理距离特征 (Haversine)	<code>spatial_features_{city}.csv</code> (N×16)
<code>build_poi_features.py</code>	OSM POI 语义特征 (11类功能性 POI, transport 已剥离)	<code>poi_features_{city}.csv</code> (N×22)
<code>build_satellite_features.py</code>	Landsat-8 DN→反射率, NDVI/NDBI/MNDWI 指数	<code>satellite_features_{city}.csv</code> (N×5)
<code>build_transit_features.py</code>	地铁站/入口/公交站密度 (OSM PBF)	<code>transit_features_{city}.csv</code> (N×6)
<code>build_subway_features.py</code>	轨道线路覆盖 (政府xlsx + OSM名称匹配) + G_transit 图	<code>subway_grid_features_{city}.csv</code> (N×2) <code>graph_transit_{city}.pt</code>
<code>build_bus_features.py</code>	公交线路数 (OSM route=bus 关系 + MTA GTFS 5区)	<code>bus_route_features_{city}.csv</code> (N×1)
<code>build_temporal_features.py</code>	时间周期编码 (sin/cos) + 节假日标志 (12维)	<code>temporal_features_{city}.csv</code> (T×12)
<code>build_graphs.py</code>	G_spatial / G_poi / G_flow 构建 + 41维节点特征合并	<code>node_features_{city}.npz</code> (N×41) <code>graph_{spatial,poi,flow}_{city}.pt</code>
<code>merge_weather.py</code>	ERA5 + OpenWeatherMap 气象字段合并, 插值至30分钟	<code>weather_{city}_merged.csv</code>
<code>preprocess_all.py</code>	一键顺序执行全部预处理步骤	— (调度器)
<code>train_stgcn.py</code>	STGCN 基线模型训练 (PyTorch Geometric)	<code>stgcn_best.pt</code>
<code>verify_env.py</code>	依赖与 GPU 环境验证	终端报告
<code>setup_env.sh</code>		<code>.venv/</code>

Conda 环境 + 依赖安装
(支持 CUDA
118/121/128 / CPU)

2.2 公共交通特征管道（三步串联）

公共交通特征的提取分三个脚本串联执行，分别产出不同粒度的特征：

```
build_transit_features.py  → 地铁站/入口/公交站密度 transit_features (N×6)
    ↓
build_subway_features.py   → 轨道线路数/换乘枢纽  subway_grid_features (N×2)
    → 轨道拓扑图          graph_transit.pt
    ↓
build_bus_features.py      → 网格内公交线路数    bus_route_features (N×1)
    ↓
build_graphs.py            → 合并 41 维节点特征矩阵 node_features (N×41)
```

北京公交数据处理

OSM 从 `route=bus` relation 关系直接提取 platform 节点成员，获取 2,098 条关系，bbox 内覆盖率 88.4%；剩余未覆盖站点通过政府 [公交站点信息.xlsx](#)（58,697 条记录，9,416 唯一站名）模糊匹配（阈值 0.80）补全 890 个站点。

纽约公交数据处理（MTA GTFS 5区）

OSM 数据对纽约 TaxiNYC bbox 覆盖率仅 41.5%，故改用 MTA GTFS 5区公交数据。5个子目录（Brooklyn / Bronx / Manhattan / Queens / Staten Island）各含完整 routes.txt 和独立 stop_times.txt。按 bbox 过滤后得 3,168 个唯一站点，255 条 route_type=3 公交线路，覆盖率 100%。

三、特征工程代码库 (src/features/)

src/features/ 为可导入 Python 包，提供 4 个独立模块和 16 个公开符号，用于在训练/评估代码中直接调用特征函数，不依赖任何中间文件路径。

3.1 模块结构

模块	文件	公开函数	功能
base	base.py	assign_to_grid haversine_km haversine_matrix minmax zscore	网格坐标分配、球面距离计算 (Haversine)、归一化工具
temporal	temporal.py	build_temporal load_bj_holidays us_federal_holidays	时间周期编码 (sin/cos, 12 维)、节假日规则 (北京/纽约)
graphs	graphs.py	build_spatial_graph build_poi_graph build_flow_graph save_graph load_graph graph_stats	G_spatial / G_poi / G_flow 构建; .pt 格式存储/加载; 边统计
node_features	node_features.py	build_node_features hist_stats	组装 (N, 41) 节点特征矩阵; 8 维历史流量统计

3.2 典型用法

```
from src.features.base import assign_to_grid, haversine_km
from src.features.temporal import build_temporal, load_bj_holidays
from src.features.graphs import build_spatial_graph, save_graph, load_graph, graph_stats
from src.features.node_features import build_node_features, hist_stats

# 加载图
g = load_graph("data/processed/graph_transit_bj.pt")
print(graph_stats("data/processed/graph_transit_bj.pt"))
# → nodes=1024, edges=3080, avg_deg=3.0

# 组装节点特征
feat = build_node_features(
    grid_csv="data/processed/grid_bj.csv",
    spatial_csv="data/processed/spatial_features_bj.csv",
    poi_csv="data/processed/poi_features_bj.csv",
```

```
satellite_csv="data/processed/satellite_features_bj.csv",
transit_csv="data/processed/transit_features_bj.csv",
subway_feat_csv="data/processed/subway_grid_features_bj.csv",
bus_feat_csv="data/processed/bus_route_features_bj.csv",
flow_npz="data/raw/taxibj/taxibj.npz",
tz_offset=8
)
assert feat.shape == (1024, 41) and feat.dtype == "float32"
```

四、41 维静态节点特征矩阵

4.1 特征维度规格

索引	分组	维度	数据来源	归一化
[0:4]	地理位置（纬度/经度/城市中心距离/环路ID）	4	坐标计算	lat/lon/dist: min-max; ring: /5
[4:6]	到交通枢纽/商业中心最短距离	2	Haversine	min-max [0,1]
[6:11]	路网密度（总/主干/地方/服务/慢行）	5	OSM PBF	log1p → z-score
[11:22]	POI 类别密度（11类功能性POI）	11	OSM PBF	log1p → z-score
[22:27]	遥感指数（NDVI / NDBI / MNDWI / B4均值 / B4标准差）	5	Landsat-8	z-score
[27:35]	历史流量统计（均值/峰值比/零值率/时段模式等）	8	TaxiBJ / TaxiNYC	见注①
[35:38]	公共交通密度（地铁站/入口/公交站）	3	OSM PBF	log1p → z-score
[38:40]	轨道线路数 / 换乘枢纽标志	2	政府数据 + OSM	log1p / binary
[40]	公交线路数	1	MTA GTFS / OSM	log1p

注①：hist_mean: min-max; p99_ratio: [0,1]; zero_rate: [0,1]; wd_peak_ratio / we_ratio: clip [0,5]; night_ratio: clip [0,1]; flow_dir: min-max; flow_cv: clip [0,5]。

4.2 各分组统计详情

路网密度（[6:11]）

城市	提取道路数	路网密度均值	说明
北京	90,380 条	10.0 km/km ²	OSM PBF 36.1 MB, UTM 50N 投影
纽约	114,938 条	34.3 km/km ²	OSM PBF 151 MB (BBBike)，曼哈顿路网密度高

POI 语义特征（[11:22]） — transport 类完全剥离

类别	北京数量	纽约数量	主要 OSM Tag
----	------	------	------------

food	5,326	10,240	amenity=restaurant/cafe/fast_food
shopping	1,920	3,809	shop=supermarket/mall/clothes/...
entertainment	249	407	leisure=cinema, amenity=theatre
office	1,838	1,811	office=*, amenity=bank
residential	104	28	building=apartments/residential
education	251	614	amenity=school/university/college
healthcare	323	1,199	amenity=hospital/clinic/pharmacy
government	265	137	amenity=townhall/police/courthouse
tourism	1,878	1,833	tourism=*, amenity=place_of_interest
sports	342	729	leisure=sports_centre/stadium/gym
religious	39	334	amenity=place_of_worship
合计	12,536	21,144	—

transport 类已完全从 POI 特征中剥离，改由独立的公共交通密度特征（[35:38]）建模，避免北京 transport 类 POI（23,549 条）主导余弦相似度导致 G_poi 图退化。

遥感特征（[22:27]）— Landsat-8

特征	公式	北京均值	纽约均值
ndvi	$(B5-B4)/(B5+B4)$	0.219	0.034
ndbi	$(B6-B5)/(B6+B5)$	-0.022	-0.070
mndwi	$(B3-B6)/(B3+B6)$	-0.225	0.009
b4_mean	红波段平均反射率	0.142	0.115
b4_std	红波段标准差	0.033	0.035

公共交通特征（[35:40]）— 详细统计

特征	北京	纽约
subway_station_density	369站，253/1024格（24.7%）覆盖	238站，41/75格（54.7%）覆盖
subway_entrance_density	983入口，208/1024格覆盖	1,153入口，41/75格覆盖
bus_stop_density	10,831站，787/1024格（76.9%），均值4.56/km ²	3,015站，66/75格（88.0%），均值12.57/km ²

num_subway_lines ([38])	208/1024格有线路，55格为换乘枢纽	41/75格有线路，33格为换乘枢纽
is_transfer_hub ([39])	binary (西直门/国贸/东直门等)	binary (Times Sq/Grand Central等)
num_bus_routes ([40])	765/1024 (74.7%) 格，均值7.6，最大64	48/75 (64.0%) 格，均值7.6，最大41

4.3 输出矩阵

(1024, 41)

float32 • 164.1 KB

node_features_bj.npy • NaN=0 ☒

(75, 41)

float32 • 12.1 KB

node_features_nyc.npy • NaN=0 ☒

五、多模态图结构（方案C 主线）

每城市构建 4 张同构图，共享同一节点集合，后续通过门控网络融合。图以 PyTorch Geometric 兼容格式存储（edge_index / edge_weight / num_nodes）。

5.1 四类图构建方法

G_spatial — 空间邻接图

Moore 8邻域，边权 = 高斯距离衰减，带宽 $\sigma=1.5$ 格：

$$w(i,j) = \exp(-d(i,j)^2 / \sigma^2)$$

正交邻居 $d=1.0 \rightarrow w=0.641$ ；斜角邻居 $d=\sqrt{2} \rightarrow w=0.411$

G_poi — POI 功能相似图

11类功能 POI 密度向量， $\log_{1p} \rightarrow L2$ 归一化 $\rightarrow$ 余弦相似度，取 top-k=10 近邻。

G_flow — 历史流量相关图

全量 inflow 时序 Pearson 相关矩阵，取 top-k=15 正相关近邻。北京相关均值 0.857，纽约 0.691。

G_transit — 轨道线路拓扑图

同一条轨道线路途经的相邻站点之间连边，边权 = $\exp(-\text{站间距}/\sigma)$ 。ChebConv 要求对称拉普拉斯，图为无向图（双向有向边实现）。北京使用政府 xlsx（18条线，342站）与 OSM 坐标匹配；纽约使用 OSM route=subway 关系（31条线，1,601节点）。

5.2 图统计汇总

城市	图	节点数	边数	边/节点	存储文件
北京	G_spatial	1,024	7,812	7.6	graph_spatial_bj.pt
北京	G_poi	1,024	10,240	10.0	graph_poi_bj.pt
北京	G_flow	1,024	15,255	14.9	graph_flow_bj.pt
北京	G_transit	1,024	3,080	3.0	graph_transit_bj.pt
纽约	G_spatial	75	484	6.5	graph_spatial_nyc.pt
纽约	G_poi	75	750	10.0	graph_poi_nyc.pt
纽约	G_flow	75	1,125	15.0	graph_flow_nyc.pt

纽约	G_transit	75	754	10.1	graph_transit_nyc.pt
----	-----------	----	-----	------	----------------------

5.3 动态时间特征（12维）

采用正弦余弦编码将周期性时间变量映射到连续向量空间：

特征名	周期	含义
slot_sin / slot_cos	48	日内第几个 30min 步（0~47）
hour_sin / hour_cos	24	小时（0~23）
weekday_sin / weekday_cos	7	星期（0=周一）
month_sin / month_cos	12	月份（1~12）
doy_sin / doy_cos	366	年内第几天
is_weekend	—	二值：0=工作日，1=周末
is_holiday	—	二值：0=普通日，1=节假日（BJ 8.0%；NYC 2.7%）

六、数据质量分析

6.1 总体评估

数据集	完整性	可用性	主要问题
TaxiBJ 人流	☑ 无缺失	高	四段不连续，非全年
TaxiNYC 人流	☑ 无缺失	高	零值比例 10.7%（边缘格正常）
METR-LA 速度	☑ 无缺失	高	速度非人流，定位为辅助基线
OpenWeatherMap 北京	⚠ 部分缺失	中	visibility/sea_level/wind_gust 100% 缺失
OpenWeatherMap 纽约	⚠ 部分缺失	中高	sea_level/grnd_level 100% 缺失
Open-Meteo ERA5	☑ 无缺失	高	字段少但全完整，作为核心气象输入
OSM 北京 / 纽约	☑ 完整	高	纽约初次下载文件 30MB（EOF 损坏），已重新获取 151MB
Landsat-8 北京 / 纽约	☑ 完整	高	单景静态特征；云覆盖率 <0.2%
北京政府交通数据	☑ 完整	高	2026年版，新线路在bbox外，无影响
MTA GTFS（5区公交）	☑ 完整	高	5区分包，100% 站点覆盖

6.2 TaxiBJ 流量统计

年份	时间步数	时间段	Inflow 均值	Inflow 最大	零值占比
BJ13	4,888	2013-07-01 ~ 2013-10-29	97.3	1,230	5.68%
BJ14	4,780	2014-03-01 ~ 2014-06-27	111.1	1,285	5.16%
BJ15	5,596	2015-03-01 ~ 2015-06-30	115.4	1,267	4.71%
BJ16	7,220	2015-11-01 ~ 2016-04-10	94.5	1,250	5.46%
合计	22,484	四段（不连续），30分钟/步，(T,2,32,32)			

6.3 OSM 关键问题记录

纽约 OSM 文件损坏问题：初次从 Geofabrik 下载文件仅 30.7MB（完整应为 151MB）。OSM PBF 格式中 Node 块先于 Way 块存储，截断文件导致 POI 节点可正常解析但道路几何完全缺失，

最终路网密度全部为 0。排查后从 BBBike 重新下载完整文件，路网（114,938条）、POI（21,144个）、公交站点（3,015个）均恢复正常。

6.4 MTA GTFS 数据结构

子目录	覆盖区	路线数 (type=3)	bbox内站点数
gtfs_bus/gtfs_b/	Brooklyn	255	648
gtfs_bus/gtfs_bx/	Bronx	255	656
gtfs_bus/gtfs_m/	Manhattan	255	1,813
gtfs_bus/gtfs_q/	Queens	255	27
gtfs_bus/gtfs_si/	Staten Island	255	156
合计 (去重)	全市	255	3,168

注：routes.txt 在5个区GTFS中内容相同（同一套全市线路），stop_times.txt各区独立（最大 ~141MB），使用 chunksize=200,000 分块读取。

七、预处理产物清单

7.1 data/processed/ 完整文件列表

文件	规格	状态
temporal_features_bj.csv	(22484, 12) 北京时间特征	☒
temporal_features_nyc.csv	(17520, 12) 纽约时间特征	☒
spatial_features_bj.csv	(1024, 16) 北京路网+距离	☒
spatial_features_nyc.csv	(75, 16) 纽约路网+距离	☒
poi_features_bj.csv	(1024, 22) 北京 POI (11类×2)	☒
poi_features_nyc.csv	(75, 22) 纽约 POI	☒
satellite_features_bj.csv	(1024, 5) 北京遥感指数	☒
satellite_features_nyc.csv	(75, 5) 纽约遥感指数	☒
transit_features_bj.csv	(1024, 6) 北京公共交通密度	☒
transit_features_nyc.csv	(75, 6) 纽约公共交通密度	☒
subway_grid_features_bj.csv	(1024, 2) 北京轨道线路特征	☒
subway_grid_features_nyc.csv	(75, 2) 纽约轨道线路特征	☒
bus_route_features_bj.csv	(1024, 1) 北京公交线路数	☒
bus_route_features_nyc.csv	(75, 1) 纽约公交线路数	☒
node_features_bj.npy	(1024, 41) float32, 164.1KB, NaN=0	☒
node_features_nyc.npy	(75, 41) float32, 12.1KB, NaN=0	☒
graph_spatial_bj.pt	edges=7,812	☒
graph_poi_bj.pt	edges=10,240	☒
graph_flow_bj.pt	edges=15,255	☒
graph_transit_bj.pt	edges=3,080	☒
graph_spatial_nyc.pt	edges=484	☒
graph_poi_nyc.pt	edges=750	☒

graph_flow_nyc.pt	edges=1,125	☒
graph_transit_nyc.pt	edges=754	☒

八、Week 2 完成情况总结

8.1 任务完成核查

状态	任务	涉及数据/文件
☒	TaxiBJ 四段时间对齐与拼接	taxibj/*.h5
☒	OpenWeatherMap 时间戳解析、缺失字段处理、插值30分钟	openweather/*.csv
☒	TaxiNYC 气象温度单位转换 (°F → °C)	taxinyc/Meteorology.h5
☒	OSM POI 提取与网格聚合 (11类功能POI, transport剥离)	osm/*.pbf
☒	Landsat-8 DN → 反射率转换, NDVI/NDBI/MNDWI 计算	Landsat8_*/B*.TIF
☒	ERA5 + OpenWeatherMap 字段合并, 30分钟气象特征矩阵	weather/*.h5 + openweather/*.csv
☒	METR-LA parquet 格式解析	metr_la/*.parquet
☒	公共交通特征 (地铁站/入口/公交站密度, 3维)	OSM PBF
☒	轨道线路特征 (num_subway_lines, is_transfer_hub, 2维)	政府xlsx + OSM PBF
☒	公交线路特征 (num_bus_routes, 1维)	OSM + MTA GTFS 5区
☒	多模态图构建 (G_spatial / G_poi / G_flow / G_transit)	各中间特征文件
☒	节点特征矩阵合并 (N×41, NaN=0)	build_graphs.py

8.2 额外完成项

- ☒ src/features/ 可导入 Python 特征工程代码库 (4模块, 16公开符号)
- ☒ 量化 / TensorRT 加速预研报告 (INT8 / FP16 方案对比, 推理加速评估)
- ☒ 可视化界面设计文档 (Streamlit + Kepler.gl 交互设计)
- ☒ 完整的 static_features_spec.md v1.4 (41维特征完整规格)
- ☒ graph_fusion_design.md (多图融合方案C最终设计)
- ☒ 数据规模差异说明 (3.7GB 实际 vs 20GB PDF估计)

8.3 Week 3 预告

下周目标：基础时空预测模型

基于本周完成的 (N,41) 节点特征矩阵和 4 类多模态图，训练并评估：ARIMA 时序基线 → LSTM 序列模型 → 标准 GCN（单图）→ STGCN（时空图卷积）。评估指标：MAE / RMSE / MAPE，在 TaxiBJ 和 TaxiNYC 两个数据集上对比。