

WEEK 3 • 2026-06-25

基线模型训练与评估

城市人流预测系统 — 第三周进度报告

数据集: TaxiBJ (北京) | 预测任务: 未来 24 小时人流量
评估划分: 训练 70% / 验证 10% / 测试 20% (时序 7:1:2)
6 个基线模型全部完成 • T_{in} 消融实验 (6h / 1天 / 1周)

1 本周目标与完成情况

1.1 任务目标

按项目文档要求，本周实现并评估三类基线模型，建立统一的评估体系，为后续多图 ST-GCN 主模型提供对比基准：

- **传统时序基线**：ARIMA、Prophet（逐网格独立训练，预测未来24小时）
- **深度学习基线**：LSTM、GRU（批量训练，共享权重）
- **基础图神经网络**：GCN、GAT（利用空间邻接图，时间序列作节点特征）

1.2 完成情况

任务	状态	备注
ARIMA 统计诊断（ADF / ACF-PACF / AIC / Ljung-Box）	☑ 完成	ARIMA(2,0,1)
ARIMA Fit-once 滚动预测（1017 格）	☑ 完成	~30 分钟
Prophet Fit-once 预测（1017 格）	☑ 完成	~20 分钟
LSTM / GRU 训练（T_in=12, T_out=48）	☑ 完成	各约 20 分钟
GCN / GAT 训练（T_in=12, T_out=48）	☑ 完成	各约 8-15 分钟
T_in 消融实验（6h / 1天 / 1周）	☑ 完成	4 模型 × 3 档
统一结果 CSV 与 MLflow 追踪	☑ 完成	week3_metrics.csv

1.3 实验设置

参数	值
数据集	TaxiBJ（22484 时间步，32×32 网格，30 分钟/步）
划分比例	训练 70% / 验证 10% / 测试 20%（时序不打乱）
训练集大小	15,679 步；验证集 2,190 步；测试集 4,438 步
输入长度（基线）	T_in = 12 步（6 小时）
预测长度	T_out = 48 步（24 小时）
优化器	AdamW（lr=0.001, weight_decay=1e-4）
损失函数	Huber Loss
早停策略	patience = 15 epochs
评估指标	MAE、RMSE、MAPE（反归一化后在原始尺度计算）

2 模型架构说明

2.1 传统统计模型

ARIMA — 统计时序诊断流程

针对 TaxiBJ 的人流时序进行了完整的三阶段统计分析：

- **阶段1 — ADF 平稳性检验：**对 30 个高活跃网格进行 Augmented Dickey-Fuller 检验，所有采样格子均已平稳（ $p < 0.001$ ），确定差分阶数 `d=0`，无需差分处理。
- **阶段2 — AIC 参数选择与残差诊断：**在 $p \in [0, 3]$ 、 $q \in [0, 2]$ 范围内进行网格搜索，最优阶数集中于 ARIMA(2,0,1) 和 ARIMA(2,0,2)，以众数确定全局阶数 **ARIMA(2,0,1)**。Ljung-Box 检验显示残差仍存在自相关（ $p < 0.05$ ），说明简单 ARIMA 无法完全捕获交通流的周期性规律。
- **阶段3 — Fit-once 滚动预测：**在完整训练集拟合一次模型参数，通过 `append(refit=False)` 滚动追加真实值更新残差状态，对全部 1,017 个非零格进行测试集预测。

Prophet

使用 Meta Prophet 分解模型，配置每日季节性（`daily_seasonality=True`）和每周季节性（`weekly_seasonality=True`），关闭年度季节性（数据仅跨 3 年）。采用 Fit-once 策略，在训练集拟合一次后直接外推至整个测试集时间范围。

节假日特征：本次未加入中国公共节假日数据。作为统一基线对比，其他模型同样未引入节假日信息，保证评估条件一致。

2.2 深度学习序列模型

NodeLSTM / NodeGRU

对每个网格节点共享同一组 RNN 参数（parameter sharing across nodes）。前向传播时将输入 `(B, N, T_in, 2)` 重塑为 `(B×N, T_in, 2)`，批量并行处理所有节点的时序，取最后隐层状态经全连接层输出 `T_out` 步预测。

超参数	LSTM	GRU
隐层维度	64	64
层数	2	2
Dropout	0.1	0.1
参数量	0.054 M	0.041 M

2.3 图神经网络模型

GCN / GAT

以 32×32 网格的地理邻接关系构建空间图 G_{spatial} （7,812 条边），节点特征为将 T_{in} 个时间步展平后的向量 $[T_{\text{in}} \times 2]$ （inflow + outflow 拼接）。两层图卷积后经全连接层输出预测。

超参数	GCN	GAT
隐层维度	64	32（ $\times 4$ heads = 128）
图卷积层数	2	2
注意力头数	—	4

3 实验结果

3.1 基线模型对比 (T_in = 12, 测试集 avg)

类别	模型	MAE ↓	RMSE ↓	MAPE ↓
传统统计模型				
统计	ARIMA(2,0,1)	44.73	74.83	110.7%
统计	Prophet	43.81	70.18	105.7%
图神经网络 (纯空间)				
GNN	GCN	37.35	63.55	82.7%
GNN	GAT	33.53	56.14	100.7%
深度学习序列模型				
深度学习	LSTM	29.02	51.54	63.0%
深度学习	GRU	29.04	51.58	61.2%

3.2 LSTM 预测误差随预测步长变化

以 LSTM（最优基线）分析误差随预测步长（h1=30min, h3=1.5h, h6=3h, h12=6h, avg=全24h）的变化趋势：

预测步长	时间跨度	MAE	RMSE	MAPE
h1 (1步)	30 分钟	13.09	22.63	28.4%
h3 (3步)	1.5 小时	16.71	29.75	34.6%
h6 (6步)	3 小时	20.95	37.48	44.5%
h12 (12步)	6 小时	25.70	45.05	57.4%
avg (全段)	24 小时均值	29.02	51.54	63.0%

误差随预测步长单调递增，短期预测（30分钟内）MAPE 仅 28.4%，24 小时平均误差达 63.0%，体现了长期预测的固有难度。

3.3 T_in 消融实验 (输入历史长度影响)

模型	6h (T_in=12)	1天 (T_in=48)	1周 (T_in=336)
LSTM	29.02	20.34	20.73
GRU	29.04	20.43	21.26

GCN	37.35	—	33.45
GAT	33.53	—	25.49

表中数值为 avg horizon MAE（↓ 越小越好）。GCN/GAT 的 T_in=48 结果因显存限制未测试。

4 分析与讨论

4.1 核心发现

1 时序建模能力是 24 小时预测的关键

LSTM/GRU ($MAE \approx 29$) 显著优于纯空间模型 GCN/GAT (MAE 33-37)，尽管后者利用了图结构。说明在 24 小时长程预测中，捕获时间依赖的能力比捕获空间依赖更为关键。ARIMA/Prophet 缺乏对交通流复杂非线性和高阶周期性的建模能力，表现最差。

2 历史窗口 1 天是 LSTM/GRU 的最优输入长度

从 6 小时延长至 1 天， MAE 从 29.02 降至 20.34 (-30%)，提升显著；但进一步延长至 1 周 ($T_{in}=336$) 并无额外收益 ($MAE=20.73$ ，甚至微幅上升)。这说明 LSTM 对超长时序的梯度传播困难，1 天内的日内周期性（早晚高峰）是最有效的预测信号。

3 图模型从更长历史中获益更多

GAT 从 6h→1 周 MAE 下降 24% (33.53→25.49)，GCN 下降 10% (37.35→33.45)。图模型没有专用的时序建模模块，依赖更长的历史特征向量来弥补这一缺陷，说明时序与空间的联合建模（即后续 ST-GCN 的方向）是更优的技术路线。

4 ARIMA 残差诊断揭示模型局限

Ljung-Box 检验显示所有测试格子的 ARIMA 残差均存在自相关 ($p < 0.05$)，拒绝白噪声假设。这说明简单 ARIMA(2,0,1) 无法捕获交通流的强周期性结构（日周期、周周期），其残差中仍含大量可预测信息，为深度学习方法的优越性提供了统计支撑。

4.2 模型局限性 (Limitation Analysis)

LSTM/GRU: 共享权重设计忽略了节点间的空间异质性——市中心与郊区的流量模式差异显著，但两者使用相同的网络权重；同时缺乏空间信息传递，相邻网格的互动规律无法被捕捉。

GCN/GAT: 将时序信息展平为静态节点特征，丢失了时间序列的顺序结构；且仅使用地理邻接图，未利用功能相似性、交通流量相关性等多模态空间关系。

ARIMA/Prophet: 均为单变量模型，无法利用相邻网格的信息；ARIMA 对强季节性序列需要 SARIMA 扩展才能充分建模（目前残差仍有自相关）；Prophet 未引入节假日特征，对春节、国庆等特殊时段预测精度下降。

通用局限: 所有基线模型仅使用出行流量一种特征，未融合 POI、卫星图像、公交地铁路网等多源时空语义特征，这是主模型的核心改进方向。

4.3 下周工作计划

- 实现多图门控融合 ST-GCN (MultiGraphSTGCN)，联合利用 $G_{spatial}$ / G_{poi} / G_{flow} / $G_{transit}$ 四张图
- 引入多源节点特征 (POI 分布、卫星影像、公交地铁特征)
- 与本周基线进行统一对比，验证多图融合与多源特征的增益
- 完成两周 / 一月 T_{in} 消融补充实验

