Week 4 模型训练与预测基线选型报告

项目名称：基于多源时空数据融合的城市级人流异常检测与预警系统
报告日期：2026-07-09
可视化与选型修订日期：2026-08-09
报告阶段：第四周 — 时空预测模型训练、消融实验与 Week5 异常检测基线选型

一、本周目标与结论概览

1.1 阶段目标

Week 4 的核心任务不是继续扩展数据工程，而是在已完成的数据修复、图结构构建、静态/时间/天气特征对齐基础上，系统训练和比较多个时空预测模型，选出最适合作为 Week 5 异常人流检测预测残差基线的模型。

Week 5 异常检测将主要依赖如下残差形式：

```
raw_residual = |observed_flow - predicted_flow|
```

因此 Week 4 的主指标以 **MAE** 为核心，同时参考 RMSE 和 MAPE：

- **MAE**：衡量正常情况下平均预测偏差，直接影响异常残差底噪；
- **RMSE**：反映尖峰/大误差，对异常误报风险敏感；
- **MAPE**：反映低流量区域的相对误差，对低流量异常检测有参考价值。

1.2 最终推荐模型

本周最终推荐 Week 5 使用：

```
AGFormer + gated context + linear residual head + 4-seed mean ensemble
```

对应结果：

模型	avg MAE	avg RMSE	avg MAPE
原 AGFormer best	16.5350	30.1288	37.35
AGFormer + linear seed42	16.1132	30.3198	36.91
AGFormer + linear 4-seed ensemble	**15.9030**	**30.2250**	**35.44**

相比 Week 4 前期最佳 AGFormer：

- MAE：16.5350 → **15.9030**，降低约 **3.82%**
- MAPE：37.35 → **35.44**，降低约 **5.11%**
- RMSE：30.1288 → 30.2250，基本持平，略高约 **0.32%**

该模型在 MAE 和 MAPE 上取得当前最佳综合表现，适合作为 Week 5 异常检测的主预测器。

二、实验设置

2.1 数据与任务设置

本周实验均基于 TaxiBJ 数据集：

配置项	设置
城市	Beijing / TaxiBJ
空间网格	32 × 32，共 1024 节点
时间粒度	30 分钟 / 步
输入长度	T_in = 48，即历史 24 小时
输出长度	T_out = 48，即预测未来 24 小时
预测目标	future inflow
动态输入	inflow + outflow + 时间编码
静态输入	leakage-free static node features，33 维
划分方式	时间顺序切分 train / val / test
间断窗口过滤	启用，窗口内必须连续 30 分钟

说明：报告中的 h1/h3/h6/h12 指标按代码实现为“前 h 个预测步的累计平均指标”，对应：

指标	时间范围
h1	未来 0.5 小时
h3	未来 1.5 小时窗口
h6	未来 3 小时窗口
h12	未来 6 小时窗口

`avg` 为完整 48 步预测窗口的平均指标。

2.2 时间与静态特征规则

时间编码使用真实时间戳，而非简单序号推算：

```
slot_sin / slot_cos
weekday_sin / weekday_cos
is_weekend
is_holiday
workday
```

静态节点特征原始为 41 维，但训练中排除了 8 维历史全数据流量统计特征，避免未来信息泄漏。因此实际输入静态特征为：

```
static_dim = 33
```

2.3 训练配置

主要深度模型使用：

```
optimizer = AdamW
loss      = HuberLoss
scheduler = ReduceLROnPlateau
patience  = 10
```

训练设备：

```
NVIDIA GeForce RTX 5080 Laptop GPU
```

本周训练期间曾遇到 Windows 更新重启导致训练中断，以及 Codex sandbox 在 WSL2 下无法访问 `/dev/dxg` 的问题。已通过将 Codex sandbox mode 调整为 `danger-full-access` 修复，后续训练均确认 CUDA 可用。

三、模型训练主线

3.1 LSTM 与 AGFormer 基线

前期对照结果表明，gap-aware LSTM 是稳定基线，但 AGFormer 在 MAE/RMSE 上明显更强：

模型	avg MAE	avg RMSE	avg MAPE	说明
LSTM gap-aware 3-seed avg	19.4941	36.8806	34.64	MAPE 较好，MAE/RMSE 较弱
AGFormer Time+Static 3-seed avg	16.9376	30.8805	37.88	明显优于 LSTM
AGFormer gated context seed42	16.5350	30.1288	37.35	Week4 前期最佳单模型

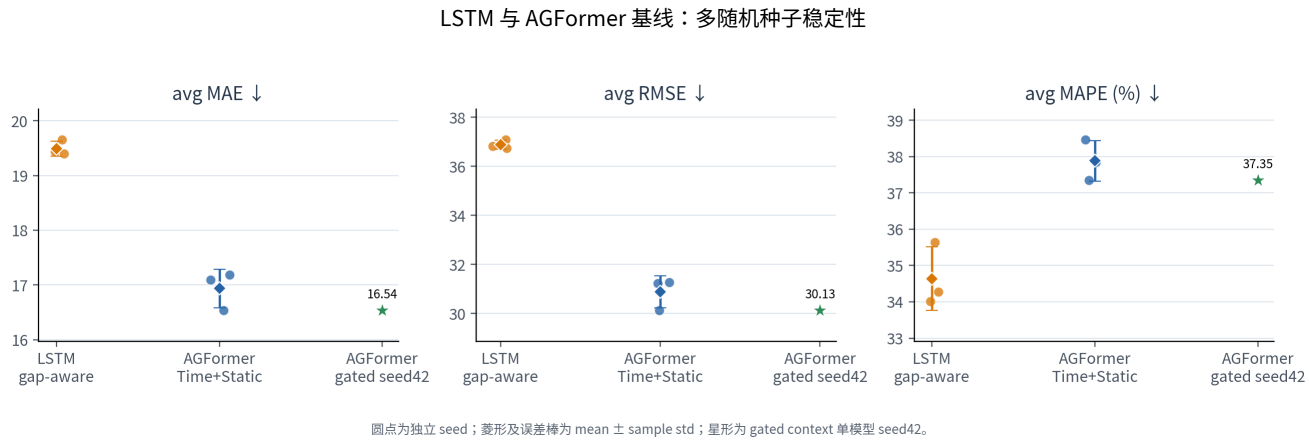


图 3-1　LSTM 与 AGFormer 基线的多随机种子结果。圆点保留每个 seed 的真实取值，误差棒为样本标准差；gated context 目前只有 seed42，故不绘制误差棒。

AGFormer 的优势主要来自：

1. 显式 spatial graph 先验；
2. adaptive adjacency；
3. temporal self-attention；
4. gated context 对时间/静态特征的稳定注入。

3.2 Spacetimeformer 系列探索

本周对 Spacetimeformer 做了多轮修正与对齐：

1. 修复真实时间戳输入；
2. 加入静态节点特征；
3. 参数匹配 AGFormer；
4. 将结构从 `chunk attention + global tokens` 改为更接近原论文的： - local temporal attention； - linear global spatiotemporal attention； - encoder-decoder target tokens； - given embedding； - value/time 分离 embedding； - decoder cross-attention；
5. 消融 future time、linear output、gated encoder context。

关键结果如下：

实验	avg MAE	avg RMSE	avg MAPE	结论
Spacetimeformer realtime context	17.9967	32.8214	37.79	修复真实时间后明显优于旧版
参数匹配版	18.6715	34.3047	39.93	加大模型未提升泛化
原版对齐 + future time	18.4433	34.4038	36.07	MAPE 改善，MAE/RMSE 不佳
原版对齐 no future time	18.2950	33.4965	37.76	关闭 future time 改善 MAE/RMSE
no future + linear output	17.0688	32.6759	37.65	linear residual 明显有效
no future + linear + gated	17.3247	33.8161	35.33	MAPE 改善，MAE/RMSE 变差

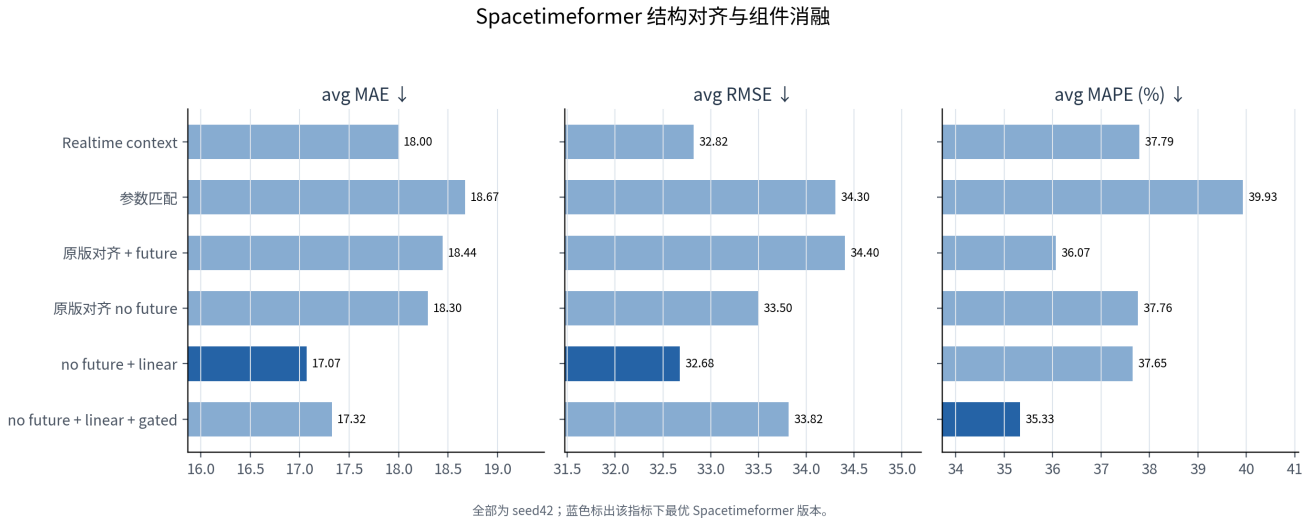


图 3-2　Spacetimeformer 系列的结构对齐与组件消融。各实验均为 seed42，颜色仅标出每项指标下的系列最优值，不代表多 seed 置信区间。

结论：

- Spacetimeformer 经过原版式结构修正后仍未超过 AGFormer；
- 其最佳版本 MAE 接近 AGFormer 多 seed 平均，但未超过 AGFormer 单模型最佳；
- linear output 对 Spacetimeformer 非常有效，提示历史 inflow 的线性趋势/残差具有强预测价值；
- 对 TaxiBJ 这类 32×32 网格流量任务，显式空间图先验比纯 attention 学习空间关系更稳定。

3.3 多图、日历、天气与周期滞后实验

Week4 还测试了多类外生特征和图结构增强。

实验	avg MAE	avg RMSE	avg MAPE	结论
Calendar context	17.8542	32.3708	42.67	完善日历后 MAE 未改善
Calendar + Weather	17.8316	32.2941	40.97	天气仅有很小改善
Multi-graph AGFormer	16.9569	30.8844	37.81	多图全局融合未超过单图
Periodic lags	17.9614	33.2339	39.52	3,433 个匹配窗口；lag_48/lag_336/delta 组合无效

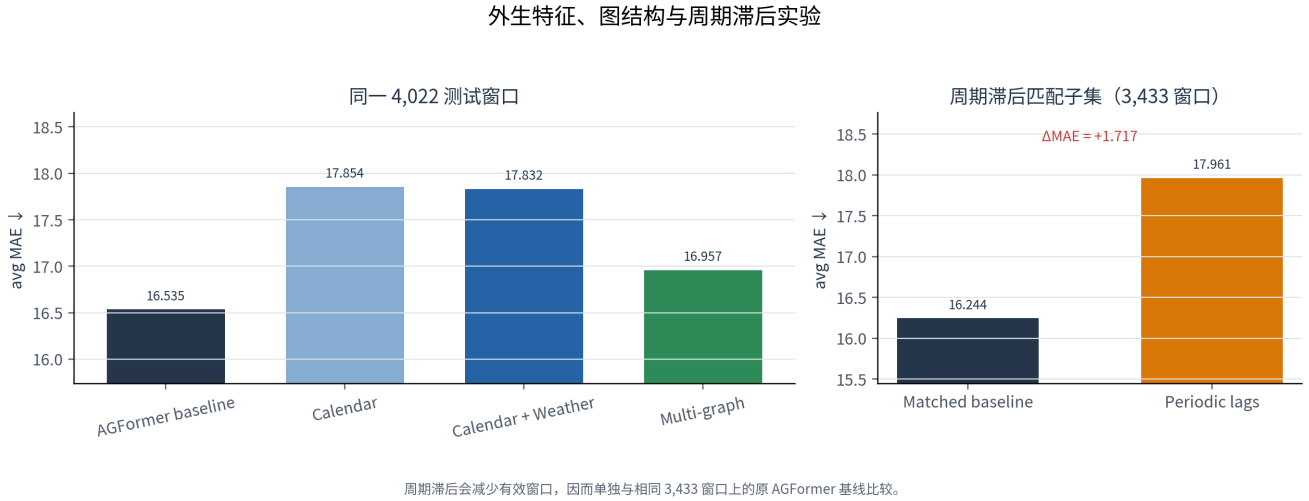
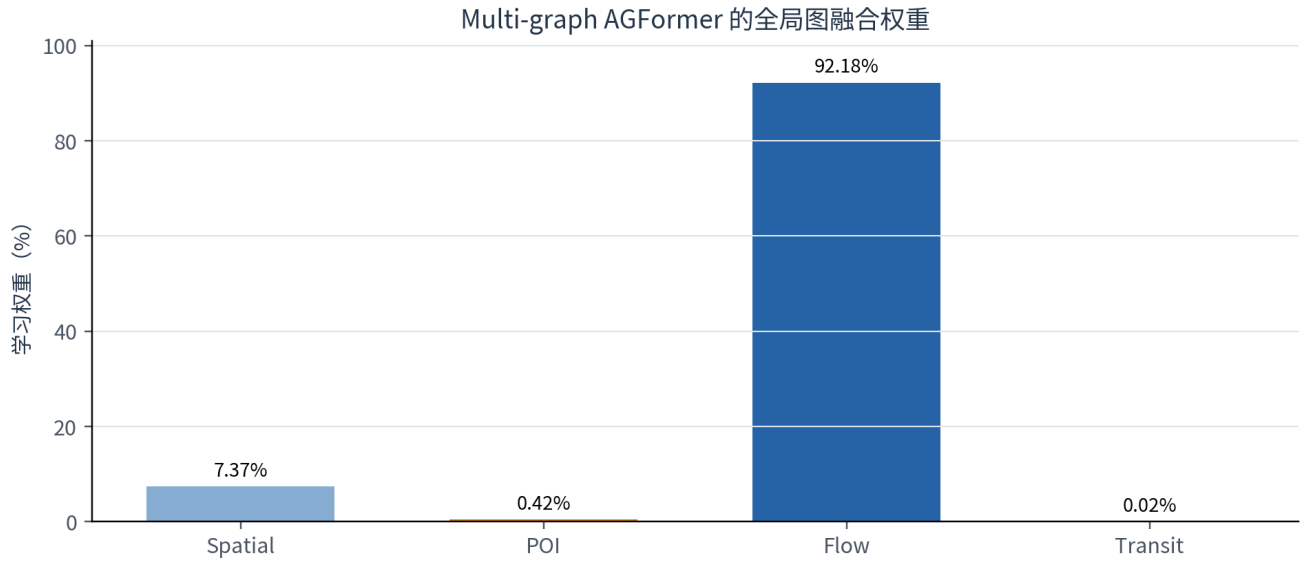


图 3-3　外生特征、图结构与周期滞后实验的 avg MAE。周期滞后会减少有效窗口，因此右图使用相同 3,433 个测试窗口上的原 AGFormer 基线（MAE 16.2443）作严格对照。

多图实验中，模型学习到的图权重大致为：

```
flow graph    ≈ 92.18%
spatial graph ≈  7.37%
poi graph     ≈  0.42%
transit graph ≈  0.02%
```



权重由 best checkpoint 中 graph_logits 经 softmax 计算；Flow graph 占比 92.18%。

图 3-4　Multi-graph AGFormer 最优 checkpoint 的全局图融合权重。权重由 graph logits 经 softmax 计算，模型明显由 flow graph 主导。

这说明当前简单全局图融合策略下，模型几乎退化为使用 flow graph，未能有效利用 POI/transit 结构。该方向后续若继续推进，应改为节点级/头级/层级动态图融合，而不是全局 softmax 融合。

四、AGFormer + Linear Residual Head

4.1 改动动机

Spacetimeformer 的 `use_linear_output: true` 带来了显著收益：

```
Spacetimeformer no future:
avg MAE 18.2950 → 17.0688
```

因此将同样思想迁移至当前最强 AGFormer：

```
prediction = AGFormer_output + Linear(history_inflow)
```

其中 `Linear(history_inflow)` 使用每个节点过去 48 步 inflow 直接映射到未来 48 步，负责捕捉强线性趋势；AGFormer 负责捕捉非线性时空残差。

4.2 单模型结果

模型	avg MAE	avg RMSE	avg MAPE
AGFormer gated context seed42	16.5350	30.1288	37.35
AGFormer + linear seed42	16.1132	30.3198	36.91

Horizon 结果：

horizon	MAE	RMSE	MAPE
h1	11.4063	19.9477	23.96
h3	13.0345	23.1312	31.06
h6	14.0216	24.8885	36.47
h12	14.6130	26.3245	37.21
avg	16.1132	30.3198	36.91

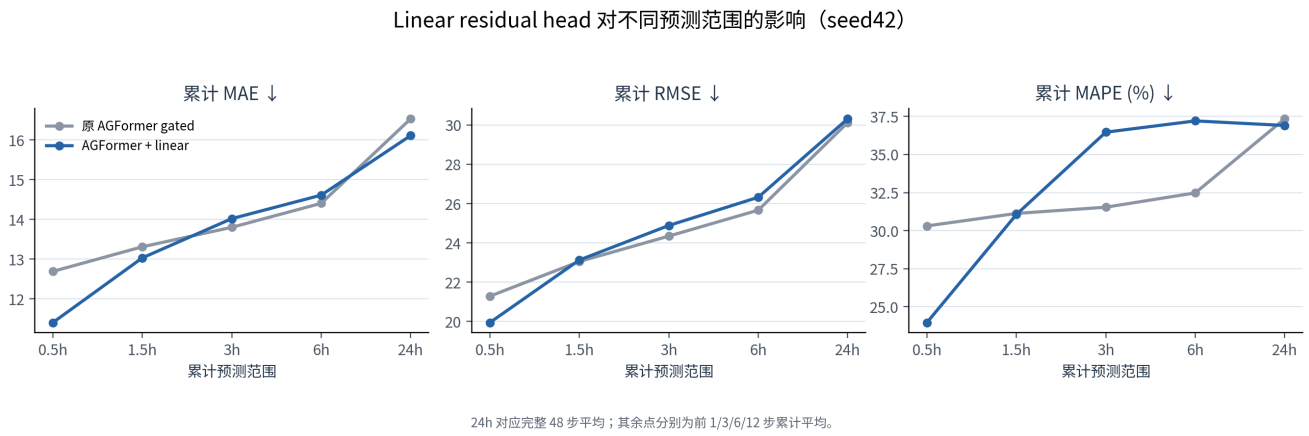


图 4-1　相同 seed42 下，原 AGFormer gated context 与加入 linear residual head 后的累计预测误差。横轴各点均为截至对应预测范围的累计平均，24h 为完整 48 步平均。

结论：

- MAE 明显改善；
- MAPE 小幅改善；
- RMSE 基本持平，略高于原 AGFormer best；
- 对短期预测 h1/h3 改善尤其明显。

4.3 多随机种子复验

为验证改动稳定性，训练了 4 个随机种子：

seed	avg MAE	avg RMSE	avg MAPE
42	16.1132	30.3198	36.91
7	16.9079	31.9627	39.75
21	16.4172	31.2766	36.51
123	16.5463	31.1309	38.10

统计结果：

指标	mean	std
MAE	16.4961	0.2850
RMSE	31.1725	0.5840
MAPE	37.8177	1.2623

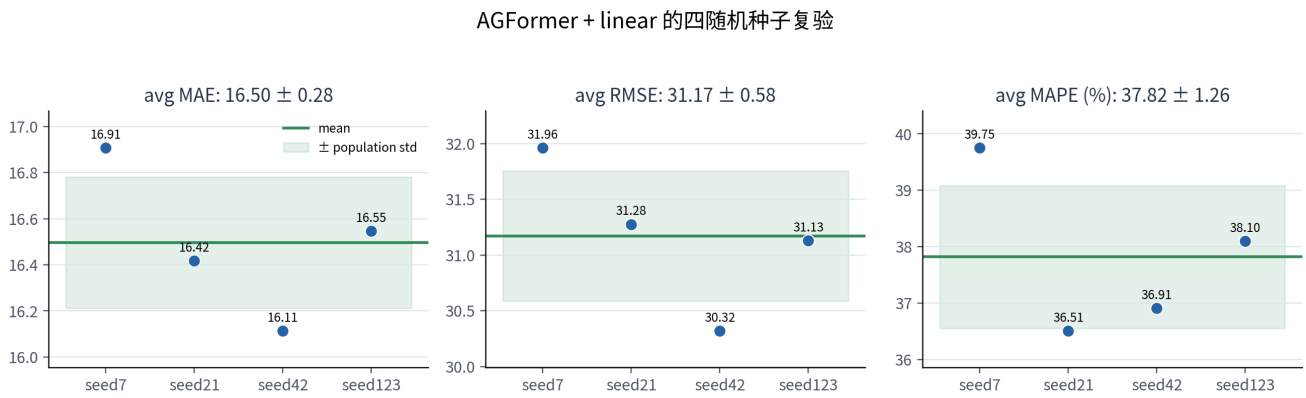


图 4-2　AGFormer + linear 的四随机种子复验。散点展示 seed42/7/21/123 的 avg 指标，水平线和阴影分别表示均值与 mean ± population std。

结论：

- seed42 是最优单模型；
- 4-seed 平均仍优于原 AGFormer best 的 16.5350；
- 说明 linear residual head 不是单 seed 偶然收益；
- 但不同 seed 波动仍存在，适合进一步做 ensemble。

五、多 seed Ensemble 评估

5.1 方法

使用 4 个 AGFormer + linear checkpoint：

```
seed42
seed7
seed21
seed123
```

对同一测试集分别推理，然后取预测均值：

```
ensemble_pred = mean(pred_seed42, pred_seed7, pred_seed21, pred_seed123)
```

该过程不重新训练，仅进行推理评估。

5.2 Ensemble 结果

horizon	MAE	RMSE	MAPE
h1	11.3019	19.8621	23.49
h3	12.6473	22.9856	26.18
h6	13.4194	24.7530	28.28
h12	14.1068	26.2676	30.66
avg	**15.9030**	**30.2250**	**35.44**

对比单模型：

模型	avg MAE	avg RMSE	avg MAPE
AGFormer + linear seed42	16.1132	30.3198	36.91
AGFormer + linear 4-seed ensemble	**15.9030**	**30.2250**	**35.44**

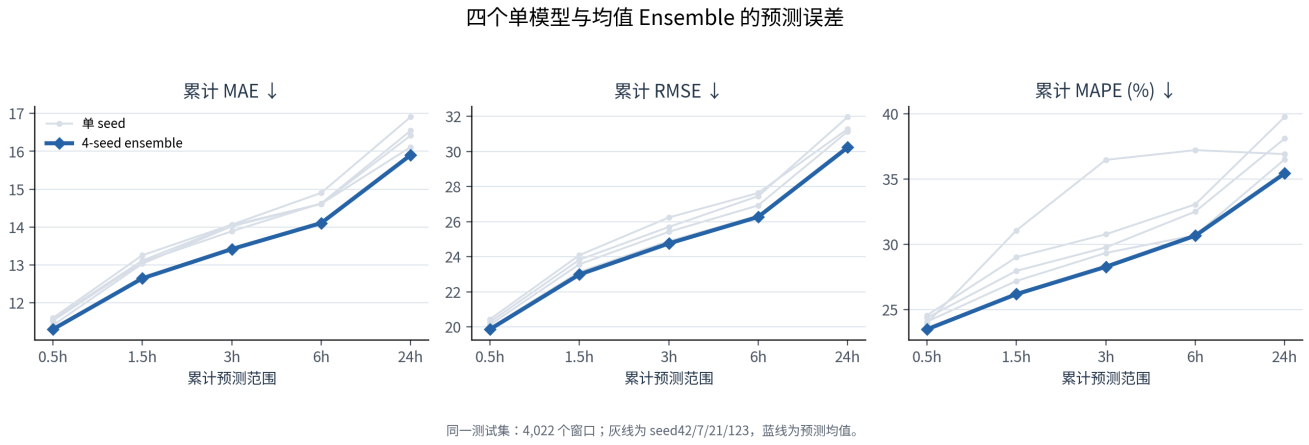


图 5-1　同一 4,022 个测试窗口上，四个单 seed 模型与预测均值 Ensemble 的累计 horizon 指标。灰线为各成员，蓝线为 ensemble。

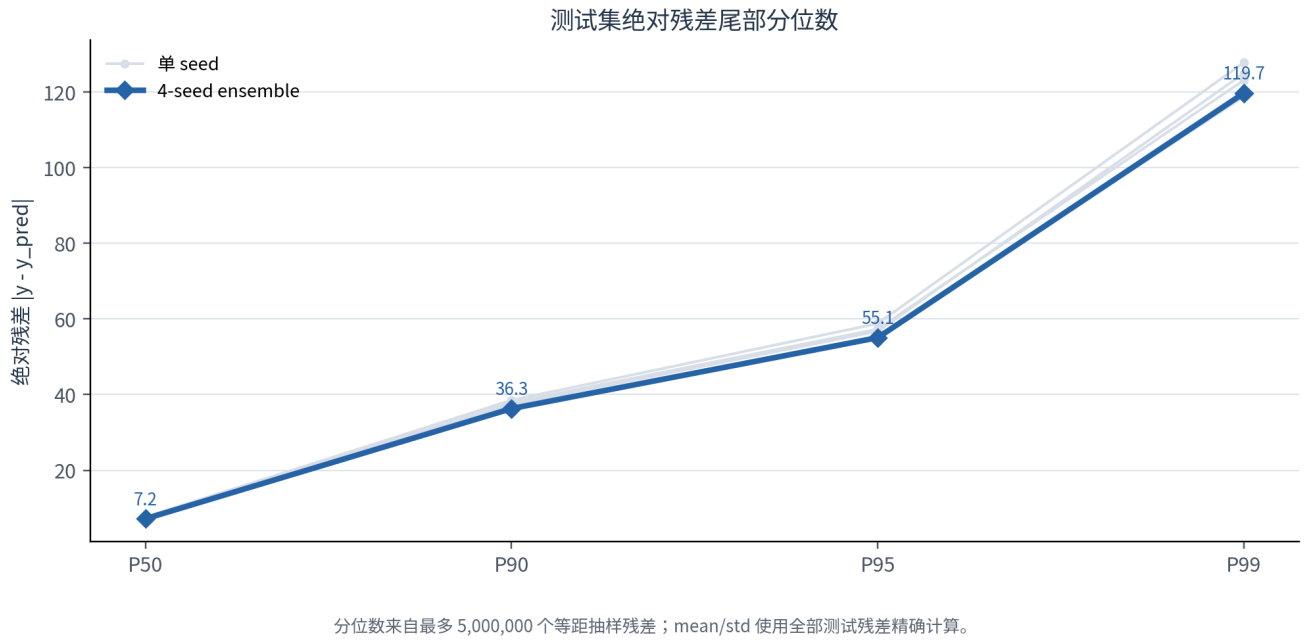
结论：

- Ensemble 进一步降低 MAE；
- MAPE 明显改善；
- RMSE 与原 AGFormer best 接近；
- 对 Week5 异常检测而言，ensemble 能降低正常样本预测噪声，适合作为主预测器。

5.3 残差分布

4-seed ensemble 测试集绝对残差分布：

统计量	abs residual
mean	15.2119
std	25.3903
p50	7.1749
p90	36.3080
p95	55.0564
p99	119.7054



分位数来自最多 5,000,000 个等距抽样残差；mean/std 使用全部测试残差精确计算。

图 5-2　单模型与 Ensemble 的绝对残差尾部分位数。由于全测试残差规模很大，分位数按评估脚本使用最多 5,000,000 个等距样本估计；mean/std 使用全部残差计算。

这些统计量可直接作为 Week5 异常检测阈值设计的起点。例如：

```
score_raw = |y - y_hat|
threshold_global = p95 or p99
```

更推荐 Week5 使用分节点、分时段的残差标准化：

```
score = |y - y_hat| / residual_scale[node, time_slot]
```

六、最终模型选择

6.1 同窗口最终候选对比

最终候选均采用真实时间编码、gap-aware 连续窗口过滤，并在同一 **4,022 个测试窗口**上评估。下表中的百分比表示 avg MAE 相对 `AGFormer gated context seed42` 的变化，负值代表改善。

模型	统计口径	单模型参数量	avg MAE（相对基线）	avg RMSE	avg MAPE
LSTM gap-aware	3-seed 指标均值	0.054 M	19.4941（+17.90%）	36.8806	**34.64**
AGFormer Time+Static	3-seed 指标均值	0.050 M	16.9376（+2.43%）	30.8805	37.88
AGFormer gated context	seed42	0.050 M	16.5350（基线）	**30.1288**	37.35
Spacetimeformer no future + linear	seed42	0.091 M	17.0688（+3.23%）	32.6759	37.65
Spacetimeformer no future + linear + gated	seed42	0.095 M	17.3247（+4.78%）	33.8161	35.33
AGFormer gated + linear	seed42	0.052 M	16.1132（−2.55%）	30.3198	36.91
AGFormer gated + linear ensemble	**4-seed 预测均值**	**4 × 0.052 M**	**15.9030（−3.82%）**	30.2250	35.44

其中“3-seed 指标均值”用于描述训练稳定性，并不等同于把三个模型的预测做 ensemble；只有最后一行执行了逐样本预测均值。

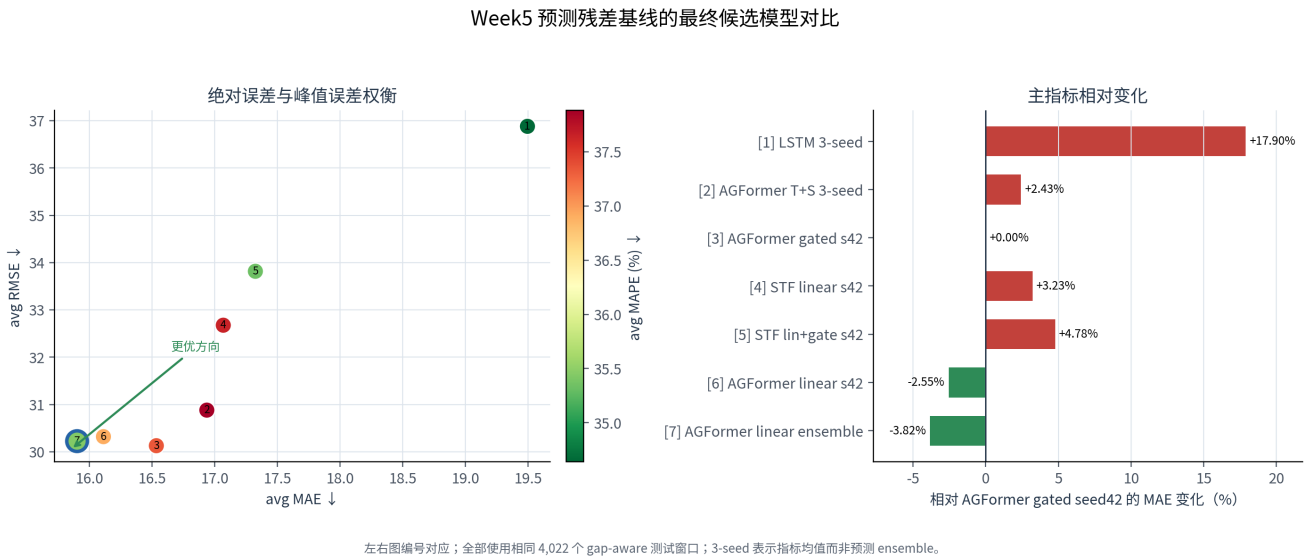


图 6-1　Week5 预测残差基线的最终候选模型对比。左图同时展示 MAE、RMSE 与 MAPE；右图以原 AGFormer gated seed42 为基线展示 MAE 相对变化。左下方向代表 MAE/RMSE 更优。

该比较揭示了三个不能被单一指标掩盖的权衡：

1. **Ensemble 的 MAE 最低**，比原 AGFormer gated 降低 3.82%，最有利于压低正常时段的预测残差底噪；
2. **原 AGFormer gated 的 RMSE 仍最低**，ensemble 的 RMSE 高 0.0962，约 0.32%，因此 ensemble 并非在所有指标上绝对支配；
3. **LSTM 的 3-seed 平均 MAPE 最低**，Spacetimeformer gated 的 MAPE 也略低于 ensemble，但二者的 MAE/RMSE 明显更差。由于 Week5 以绝对预测残差为主要异常信号，不能仅凭 MAPE 选主模型。

6.2 精度、稳定性与部署成本

Linear residual head 的四个 seed 平均 MAE 为 `16.4961 ± 0.2850`；原 AGFormer Time+Static 的三个 seed 为 `16.9376 ± 0.3520`。这支持 linear head 的收益具有跨 seed 一致性，但两组 seed 集合及标准差口径并不完全相同，因此这里只作为稳定性证据，不作为严格配对显著性检验。

最终部署成本比较如下。推理次数是理论 forward-pass 数量，不是实测延迟；四模型可以串行执行以节省显存，也可以并行执行以降低墙钟时间。

方案	每批推理次数	总存储参数量	avg MAE	相对 AGFormer+linear seed42	适用场景
AGFormer gated seed42	1	0.050 M	16.5350	+2.62%	保留最低 RMSE 的审计基线
Spacetimeformer + linear seed42	1	0.091 M	17.0688	+5.93%	架构对照，不建议作为主部署模型
AGFormer + linear seed42	**1**	**0.052 M**	**16.1132**	**基线**	低延迟、低显存单模型部署
AGFormer + linear 4-seed ensemble	**4**	**约 0.210 M**	**15.9030**	**−1.30%**	Week5 离线/批量异常检测主模型

相对最优单模型 seed42，ensemble 进一步改善：

- MAE：降低约 **1.30%**；
- RMSE：降低约 **0.31%**；
- MAPE：降低约 **3.99%**；
- 代价：需要保存并执行 4 个 checkpoint，理论计算量约为单模型的 4 倍。

6.3 Week5 主模型与降级方案

推荐主模型：

```
AGFormer + gated context + linear residual head + 4-seed mean ensemble
```

推荐理由：

1. 当前所有实验中 avg MAE 最低；
2. MAPE 同时优于原 AGFormer；
3. 显式 spatial graph 适合 TaxiBJ 网格人流预测；
4. linear residual head 明显增强短期预测；
5. ensemble 可降低异常检测中的正常残差噪声；
6. 四个 checkpoint 已训练完成，可直接进入 Week5 残差生成。

若 Week6 API 的实时延迟或显存预算不允许四模型 ensemble，则采用 `AGFormer + linear seed42` 作为降级方案。它只需一次推理，MAE 仅比 ensemble 高 0.2102，同时仍优于原 AGFormer gated。

最终角色划分如下：

用途	模型	说明
Week5 主预测残差	AGFormer + linear 4-seed ensemble	MAE 最低，优先保证异常残差底噪
实时/资源受限降级	AGFormer + linear seed42	单模型 MAE 最优，只需一次推理
RMSE 审计参考	原 AGFormer gated seed42	RMSE 最低，用于检查尖峰误差权衡
相对误差参考	Spacetimeformer linear + gated	MAPE 35.33，但 MAE/RMSE 不适合作主模型
传统深度基线	LSTM gap-aware	3-seed 平均 MAPE 最低，但绝对误差明显偏高

七、工程产物

7.1 新增/修改模型代码

文件	内容
`src/models/agformer.py`	新增 `use_linear_output`，支持 AGFormer 输出叠加线性残差头
`src/models/spacetimeformer.py`	重构为更接近原版 Spacetimeformer 的 encoder-decoder/local-global attention 结构
`scripts/train.py`	支持 AGFormer/Spacetimeformer 新配置字段
`scripts/evaluate_agformer_linear_ensemble.py`	新增多 seed ensemble 评估脚本
`scripts/generate_week4_report.py`	从保留的实验结果生成第 3–5 章图表，并重建 HTML/PDF 报告

7.2 关键配置文件

配置	说明
`configs/agformer_gate_context_linear_seed42.yaml`	最优单模型 seed42
`configs/agformer_gate_context_linear_seed7.yaml`	多 seed 复验
`configs/agformer_gate_context_linear_seed21.yaml`	多 seed 复验
`configs/agformer_gate_context_linear_seed123.yaml`	多 seed 复验
`configs/spacetimeformer_original_aligned_seed42.yaml`	原版对齐 Spacetimeformer
`configs/spacetimeformer_original_aligned_no_future_time_linear_seed42.yaml`	最优 Spacetimeformer 消融

7.3 关键结果文件

文件	内容
`outputs/results/week3_metrics.csv`	所有训练结果汇总
`outputs/results/agformer_gate_context_linear_ensemble_4seed.json`	ensemble 评估与残差统计
`outputs/results/agformer_multigraph_weights.json`	多图 checkpoint 的 graph logits 与 softmax 权重快照
`outputs/checkpoints/agformer_gate_context_linear_seed42/best.pt`	最优单模型 checkpoint
`outputs/checkpoints/agformer_gate_context_linear_seed7/best.pt`	ensemble 成员
`outputs/checkpoints/agformer_gate_context_linear_seed21/best.pt`	ensemble 成员
`outputs/checkpoints/agformer_gate_context_linear_seed123/best.pt`	ensemble 成员

八、经验总结与失败分析

8.1 Spacetimeformer 未超过 AGFormer 的原因

虽然理论上 Spacetimeformer 具有更通用的全局时空建模能力，但在本项目中未超过 AGFormer。主要原因包括：

1. TaxiBJ 是规则网格流量任务，局部空间邻接关系非常强；
2. AGFormer 显式使用 spatial graph，提供了强先验；
3. Spacetimeformer 需要从数据中自行学习空间关系，在 1024 节点规模下更难；
4. 当前训练样本数量不足以充分发挥大规模全局 attention 的优势；
5. 实验显示 linear residual 对所有模型都非常重要，说明强线性趋势本身已解释大量预测信号。

8.2 多图融合未提升的原因

当前多图实验采用全局可学习图权重，最终几乎被 flow graph 主导。该机制过于粗粒度，无法根据节点、时间或注意力头动态选择图结构，因此未能充分利用 POI/transit 语义图。

后续若继续做多图，应考虑：

```
node-wise graph gating
head-wise graph attention
layer-wise graph fusion
time-conditioned graph mixing
```

8.3 Future time 的影响

Spacetimeformer 中加入 decoder future time 后：

- MAPE 改善；
- MAE/RMSE 变差。

说明未来时间特征可能帮助低流量相对误差，但会引入额外噪声，影响绝对误差。Week5 主线不建议依赖 future time decoder。

九、Week5 交接建议

9.1 预测残差生成

Week5 建议直接使用 4-seed ensemble 生成预测：

```
members:
- agformer_gate_context_linear_seed42
- agformer_gate_context_linear_seed7
- agformer_gate_context_linear_seed21
- agformer_gate_context_linear_seed123

prediction = mean(member_predictions)
residual = |observed - prediction|
```

9.2 异常分数建议

第一版异常分数：

```
score_raw = |y - y_hat|
```

更推荐的标准化异常分数：

```
score_norm = |y - y_hat| / (residual_scale[node, slot] + eps)
```

其中 `residual_scale[node, slot]` 可由验证集或训练集滚动预测残差估计，按节点和日内 48 个 slot 分组。

9.3 阈值策略

可从以下阈值开始：

阈值	用途
residual p95	高召回预警
residual p99	高精度预警
node-slot p95	分区域分时段自适应预警
EWMA residual	连续异常检测

9.4 Week5 推荐任务顺序

1. 使用 ensemble 在 test/validation 上生成预测与残差；
2. 计算 global / per-node / per-slot 残差分布；
3. 实现 raw residual 与 normalized residual 两种 anomaly score；
4. 构造无监督异常阈值；
5. 若有异常标签，评估 precision / recall / F1；
6. 做可视化：异常区域热力图、时间序列残差图、Top-K 异常事件列表。

十、本周结论

Week4 完成了从模型训练、特征消融、结构改造到多 seed ensemble 的完整实验链路。核心结论如下：

1. **AGFormer 仍是本项目最适合的主模型**，显式空间图先验对 TaxiBJ 网格流量预测非常有效；
2. **linear residual head 是本周最有效的结构改动**，显著提升 AGFormer 与 Spacetimeformer；
3. **Spacetimeformer 经原版式对齐后仍未超过 AGFormer**，说明在本任务中显式图先验优于纯全局 attention；
4. **多 seed ensemble 进一步刷新最佳 MAE/MAPE**，是 Week5 异常检测的推荐预测基线；
5. Week5 应从“继续训练模型”转向“基于最优预测器构造残差异常分数与阈值体系”。

最终推荐：

```
Week5 主预测器 = AGFormer + gated context + linear residual head + 4-seed mean ensemble
```

最终指标：

```
avg MAE  = 15.9030
avg RMSE = 30.2250
avg MAPE = 35.44
```