Week7 最终模型性能评估报告

TaxiBJ · AGFormer gated+linear 四随机种子集成 · 生成日期 2026-08-09

> 结论摘要： 最终模型在 4,022 个严格 gap-aware 测试窗口上取得 h1 MAE 11.3019、24 小时平均 MAE 15.9030。四 seed 均值集成相对最佳单模型的 24 小时平均 MAE 再降低 1.30%。异常融合在 Level-A 弱标签上 timestep F1 为 0.4912、事件 F1 为 0.4819；这些异常指标只表示弱规则一致性，不是真实业务准确率。

1. 评估目标与固定口径

- 城市与数据：TaxiBJ，32×32 网格，共 1,024 个节点；
- 输入/输出：过去 48 个半小时步预测未来 48 步，即 24 小时到 24 小时；
- 测试窗口：4,022 个，使用真实时间戳并过滤跨缺口窗口；
- 最终模型：AGFormer，`d_model=32`、4 个注意力头、2 层，输入含流量、时间上下文及 33 维无泄漏静态节点特征，并使用 linear residual head；
- 集成成员：seed 42、7、21、123，预测按算术平均融合；
- 预测指标：对真实值非零位置计算 MAE/RMSE/MAPE，MAPE 使用 `eps=1.0`；
- 模型选择在验证集完成，本报告只汇报固定测试集结果。

2. 最终预测精度

scope	forecast_hours	MAE	RMSE	MAPE	test_windows
h1	0.5000	11.3019	19.8621	23.4913	4022
h3	1.5000	12.6473	22.9856	26.1838	4022
h6	3.0000	13.4194	24.7530	28.2789	4022
h12	6.0000	14.1068	26.2676	30.6591	4022
avg	24.0000	15.9030	30.2250	35.4350	4022

`h3/h6/h12` 是前 3/6/12 步累计指标，而不是单独第 3/6/12 步；`avg` 汇总全部 48 个预测步。

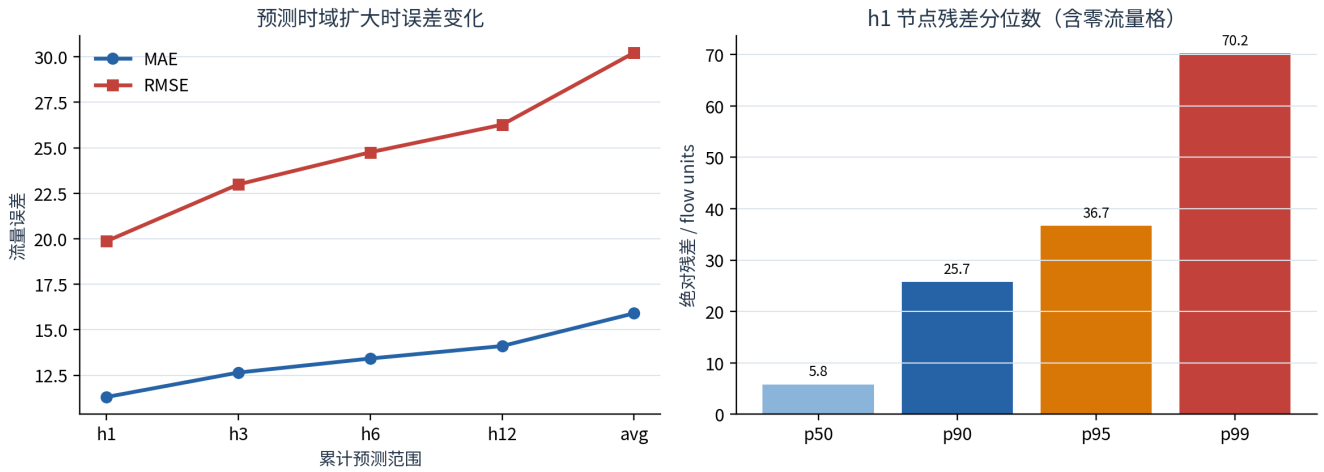


图1　随着预测时域扩大，误差逐步上升；右图展示 h1 节点绝对残差的长尾。

四个单模型的 24 小时平均结果如下。最佳单模型 seed42 的 MAE 为 16.1132，ensemble 为 15.9030，说明多 seed 平均主要降低了随机初始化带来的方差。

seed	MAE	RMSE	MAPE
42	16.1132	30.3198	36.9075
7	16.9079	31.9627	39.7537
21	16.4172	31.2766	36.5076
123	16.5463	31.1309	38.1018

3. 时间与空间误差结构

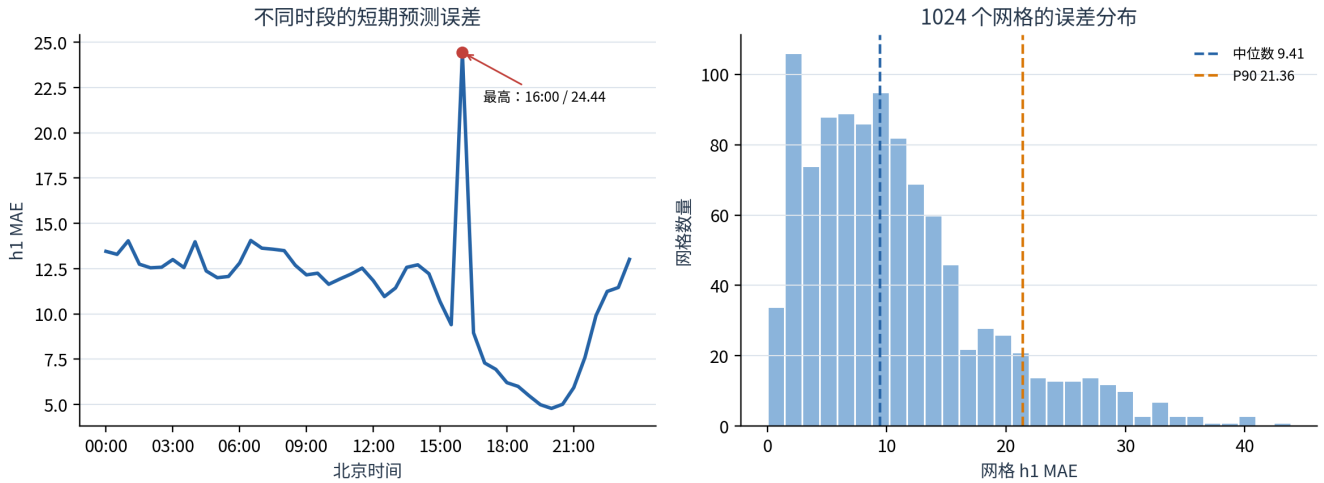


图2　左：h1 MAE 的北京时间分布；右：1,024 个网格的 h1 MAE 分布。

网格 MAE 中位数为 9.4145，P90 为 21.3621。最困难网格为 grid 157，MAE 43.8480。时段上 16:00 的误差最高，明显高于相邻时段，提示后续应针对突变日或特殊日期检查该时段的样本构成。

误差最高的时段：

local_time	MAE	RMSE	MAPE
16:00	24.4416	53.8438	66.5362
06:30	14.0519	25.2563	21.2142
01:00	14.0341	24.4249	17.7950
04:00	13.9813	25.8399	19.2839
07:00	13.6271	23.5358	40.6575

误差最高的网格：

grid_id	MAE	RMSE	MAPE	valid_count
157	43.8480	67.1035	23.9579	4022
219	40.2592	61.4400	15.5342	4021
375	40.1303	64.8538	21.5161	4022
126	39.9037	58.2741	19.6989	4021
188	39.2566	60.7336	17.7643	4021
600	37.0505	58.7574	16.1855	4022
597	35.4630	53.9794	18.2355	4022
588	35.3833	53.1877	18.3462	4021
250	35.2037	52.5031	13.7888	4020
281	35.0104	51.5775	21.2021	4022

4. 异常检测 timestep 评估

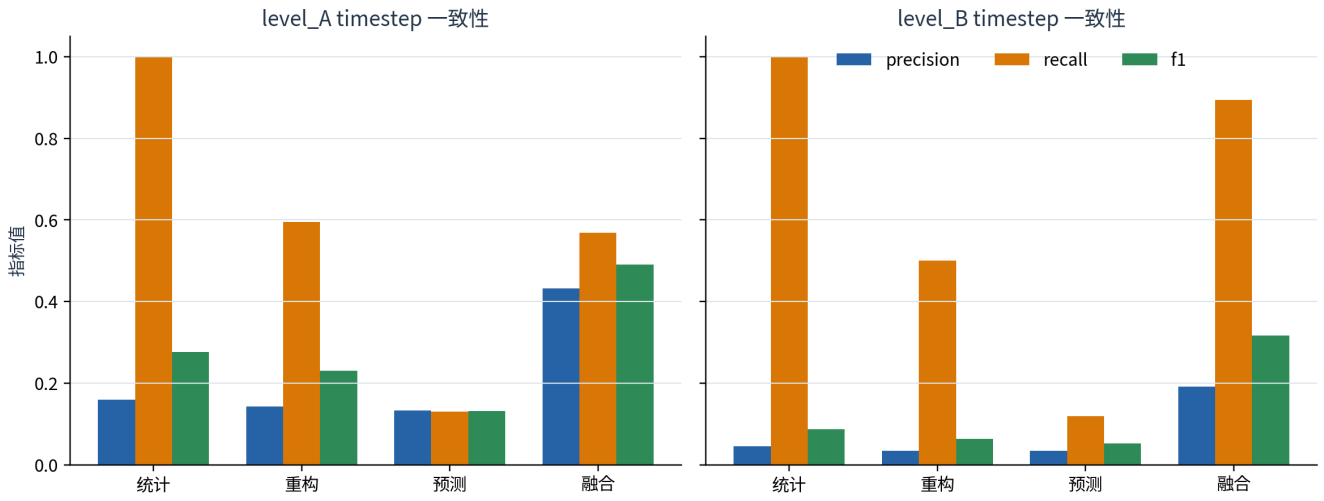


图3　统计、重构、预测误差和最终融合对两套弱标签的 timestep precision/recall/F1。

最终融合结果：

label_reference	accuracy	balanced_accuracy	precision	recall	f1	roc_auc	average_precision
level_A	0.9212	0.7576	0.4322	0.5688	0.4912	0.9335	0.4608
level_B	0.9269	0.9111	0.1921	0.8947	0.3163	0.9689	0.4436

Level-A 的 F1 更高，Level-B 的 recall 和 balanced accuracy 更高但 precision 较低。融合结果优于任一单类检测器的 F1，说明三类证据具有互补性；但统计检测同时参与弱标签构造和最终融合（权重 0.70），因此这些数值存在规则相关性。

5. 时空事件级评估

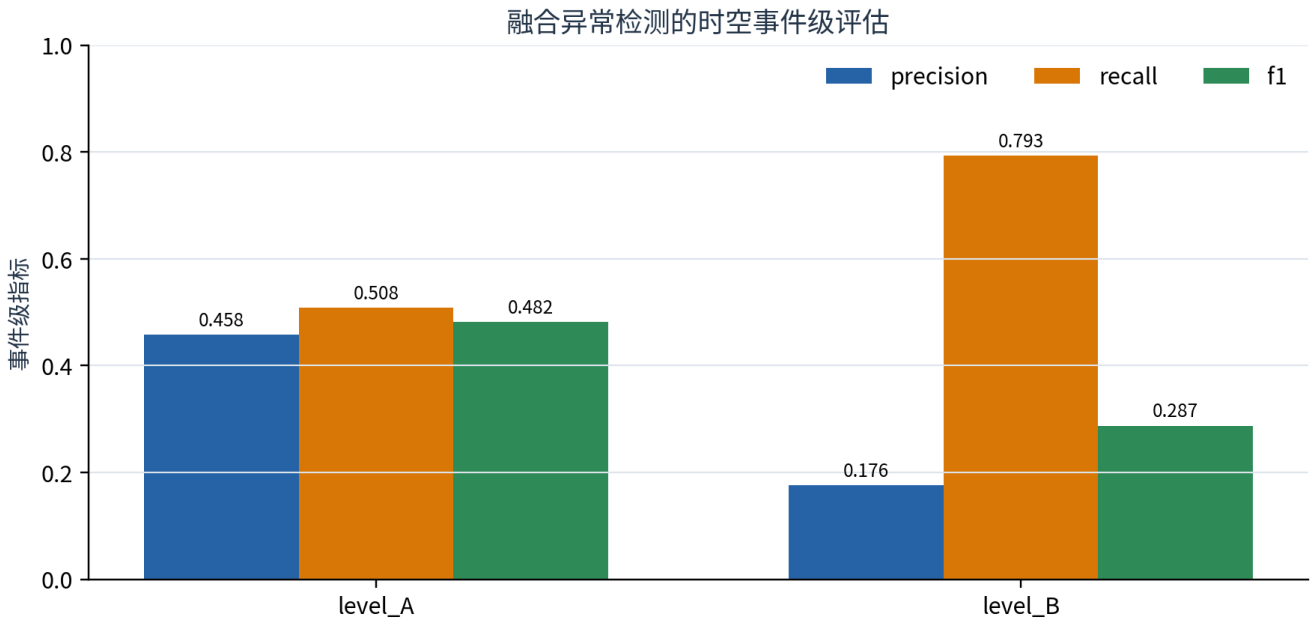


图4　事件匹配同时要求时间重叠以及空间 IoU 或质心距离满足阈值。

label_reference	event_precision	event_recall	event_f1	true_event_count	pred_event_count	mean_detection_delay_hours
level_A	0.4580	0.5085	0.4819	118	131	0.1833
level_B	0.1756	0.7931	0.2875	29	131	0.0217

最终双向融合产生 131 个事件。Level-A 参考下事件 F1 为 0.4819；Level-B 参考更严格、事件数更少，recall 达 0.7931，但 precision 下降。匹配采用一对一最大基数匹配，并在非连续 30 分钟时间缺口处强制断开事件。

6. 综合判断

1. 最终 AGFormer ensemble 可作为 Week5/Week6 预测误差检测和在线预测服务的固定模型；
2. h1 表现明显优于长时域，Web 端展示 24 小时预测时应同时提示不确定性随时域增长；
3. 网格和时段误差具有显著异质性，grid 157 和 16:00 时段值得后续专项诊断；

4. 异常融合提升了弱标签一致性，但 TaxiBJ 无权威异常真值，不能将 precision/recall 解释为现实事件检测准确率。

7. 评估边界与复现

- 预测指标是固定测试集结果，不代表其他城市或未来年份的泛化能力；
- h1 残差分位数图包含零流量格，仅用于描述检测阈值面对的残差分布，不应与 masked MAE 混用；
- 异常 weak label 来自项目统计规则，且最终融合包含统计分支；
- 原始结果位于 `outputs/week7_evaluation/final_system_v1/`，配置为 `configs/week7_evaluation.yaml`；
- 输入结果哈希、依赖版本和环境信息记录在该目录的 `summary.json`。