Week7 系统性能测试报告

Week6 生产流水线与 FastAPI 服务 · 固定 TaxiBJ 24 窗口基准 · 生成日期 2026-08-09

> 结论摘要： 生产可部署的 FP32 执行优化将暖启动流水线从 6.416s 降至 4.613s，端到端加速 1.39×；进程树 RSS 汇总下降 53.9%，CUDA 峰值分配下降 14.8%。FP16 精度门槛通过但本轮速度门槛未通过，动态 INT8 只保留为 CPU fallback 候选，生产继续使用 FP32。

1. 测试对象与控制变量

- 固定输入：测试集末尾 24 个连续有效窗口；
- 固定模型：AGFormer gated+linear 四 seed ensemble；
- 固定输出：h1 异常残差、48 步同 origin 预测、三类异常分数、融合掩码与事件；
- baseline：batch=8、2 个 DataLoader workers、分别执行 h1 与 forecast、每次重拟合统计量；
- optimized：batch=8、worker=0、共享 full-sequence 推理、统计缓存、关闭未使用注意力矩阵物化；
- 每个 pipeline variant 单次顺序执行；API 每端点 2 次 warm-up + 100 次本机顺序请求。

2. 端到端耗时与资源

name	pipeline_seconds	model_inference_seconds	forecast_inference_seconds	statistical_seconds	peak_rss_
baseline_fp32	6.4161	2.0058	1.7411	1.7231	3881.519
optimized_cold_fp32	6.1063	3.0868	0.0000	1.9276	2793.195
optimized_warm_fp32	4.6133	3.3640	0.0000	0.0377	1791.152
optimized_warm_fp16	4.5962	3.3825	0.0000	0.0336	1894.378

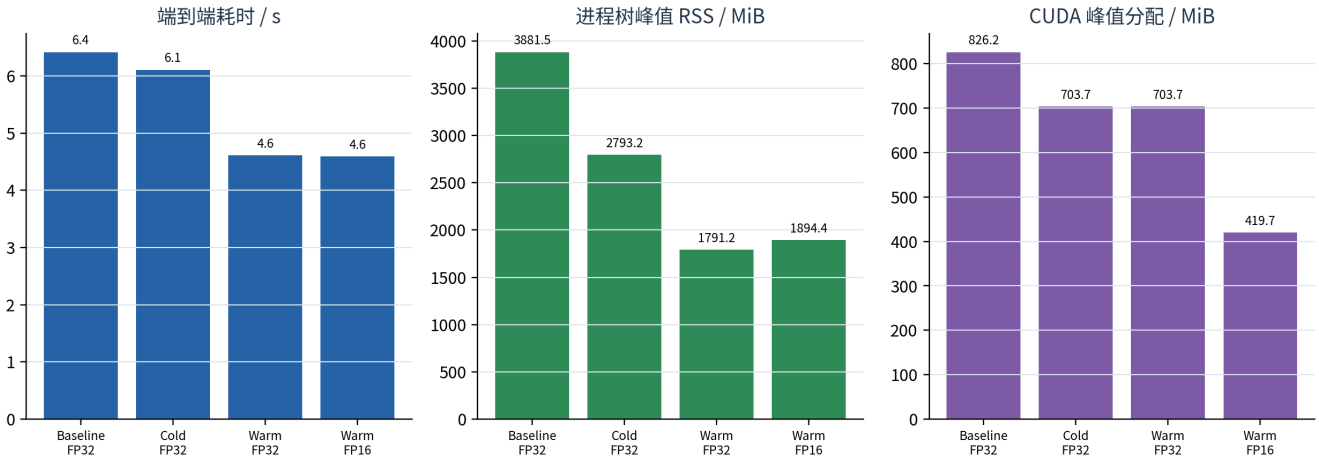


图1　各执行策略的端到端耗时、进程树 RSS 汇总和 CUDA 峰值分配。

暖启动 FP32 是正式生产候选：端到端加速 1.39×，同时减少 worker 带来的进程树 RSS。冷启动 FP32 仍需构建统计缓存，因此只获得较小收益。

3. 瓶颈定位与代码优化

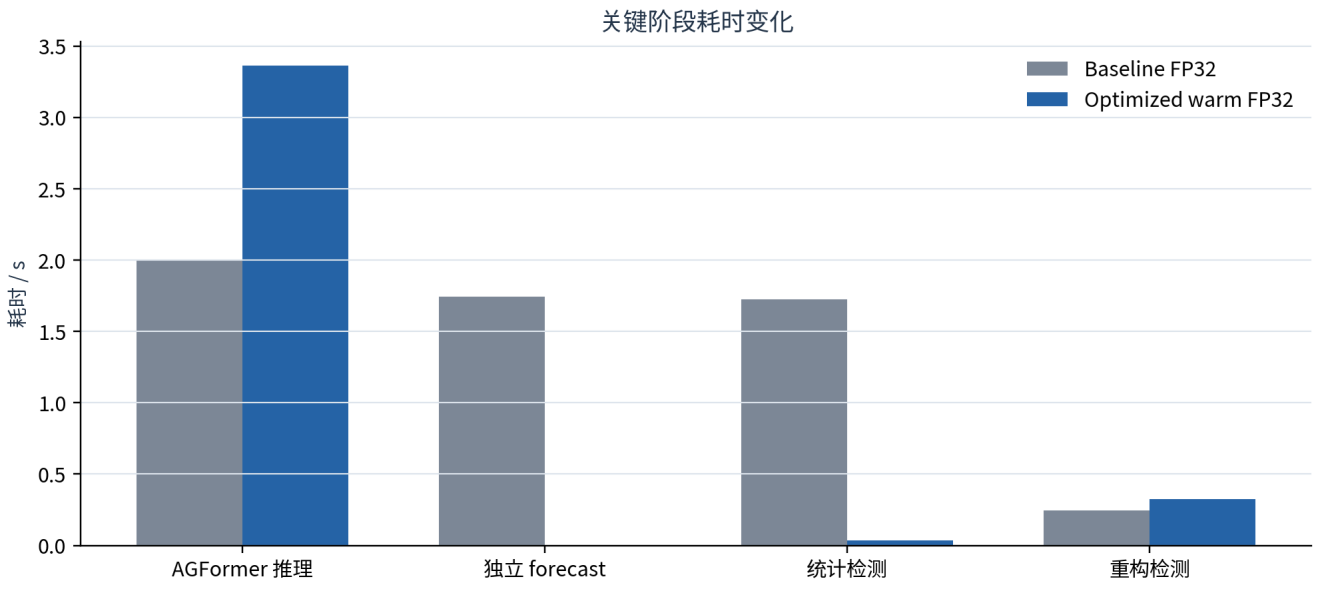


图2　baseline 与 optimized warm FP32 的关键阶段耗时。

瓶颈	修改	结果
h1 与 Web forecast 重复加载四个 checkpoint 并重复前向	24 个窗口一次输出完整序列，h1 与最新 forecast 共享	独立 forecast 阶段由 1.741s 降至近 0
每次实时调用都拟合 inflow/outflow slot statistics	以数据 SHA256、train_len、时区与规则参数构建指纹缓存	统计阶段由 1.723s 降至 0.038s
MultiheadAttention 默认返回但调用方丢弃权重	普通预测 `need_weights=False`，XAI 时显式开启	FP32 fusion mask 保持完全一致
24 窗口仍启动 2 个 DataLoader workers	实测后改为 worker=0	减少进程树 RSS 与启动开销
API 每次重新转换事件时间并循环映射坐标	mtime-aware 派生缓存 + vectorized merge	历史事件/统计端点明显加速

4. Batch size 扫描

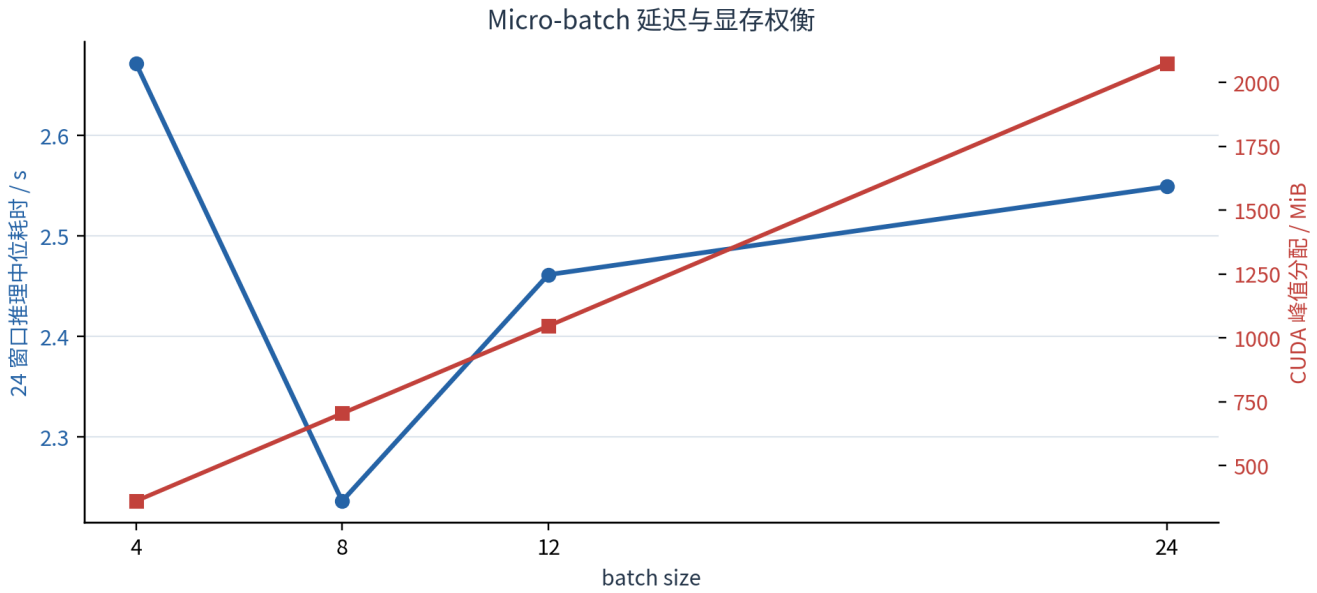


图3　24 个窗口、四模型 ensemble 在不同 micro-batch 下的延迟与 CUDA 显存。

batch_size	latency_seconds_median	latency_seconds_min	latency_seconds_max	cuda_peak_allocated_mib_max	max_abs_dif
4	2.6718	2.3823	2.9613	360.4971	0.0000
8	2.2359	2.1229	2.3489	703.7471	0.0000
12	2.4614	2.3596	2.5632	1045.9971	0.0000
24	2.5491	2.4911	2.6071	2074.2471	0.0000

batch=8　的中位延迟最低；batch=24　将峰值显存推至约　2,074　MiB，速度反而变慢。因此正式配置选择 batch=8，而不是盲目使用最大 batch。

5. 数值一致性门禁

- FP32 scores 的 fusion mask 不一致率：0.0；
- FP32 h1 `pred_flow` 最大绝对差：0.00012207；
- forecast 的 city/member/origin/timestamps 完全一致，target indices/step 完全一致；
- 48×1024 forecast 最大绝对差：0.00009155，低于 0.001 门槛；
- 正式判断：`deploy_fp32_execution_optimizations=True`。

6. FP16 与动态 INT8

FP16 对四个时期的 256 个窗口进行了补充核验：masked MAE 从 10.305124 变为 10.305077，变化 -0.000048；融合掩码不一致率为 0.0。质量门槛通过，但同轮模型推理加速比仅 0.9945×，低于 1.05，因此 `deploy_fp16=False`。

CPU dynamic INT8 microbenchmark 的速度比为 1.305×，state_dict 仅缩小 1.24%，且只覆盖单模型、单窗口和 Linear 动态量化。当前生产推理在 CUDA 上运行，因此不部署 INT8，只把它记录为 CPU fallback 候选。

7. API 响应性能

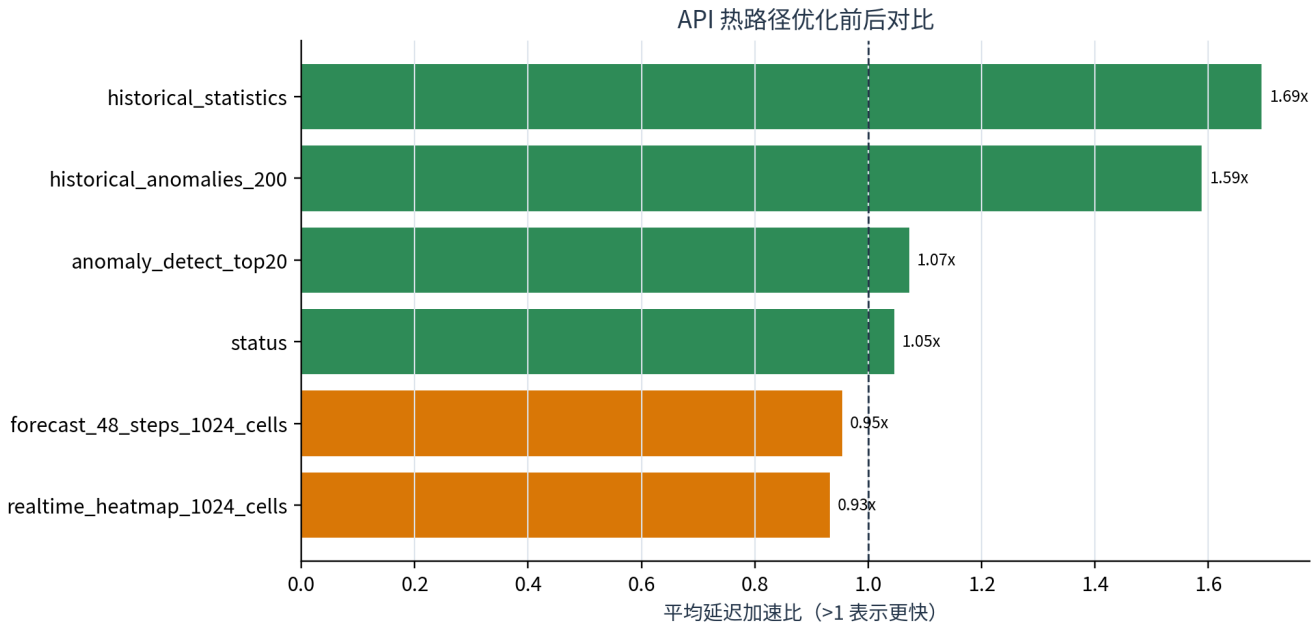


图4　优化后平均延迟相对 Week7 初始固定 API 基线的比值。

endpoint	mean_ms_baseline	mean_ms_optimized	p95_ms_baseline	p95_ms_optimized	mean_speedup
status	1.3308	1.2725	1.4688	1.5758	1.0458
realtime_heatmap_1024_cells	12.4769	13.3823	13.2446	15.9920	0.9323
forecast_48_steps_1024_cells	41.8862	43.9020	43.0060	46.6114	0.9541
anomaly_detect_top20	4.3330	4.0410	5.3741	5.0019	1.0723
historical_anomalies_200	19.4158	12.2232	20.7733	13.7642	1.5884
historical_statistics	16.8250	9.9307	18.0365	11.7588	1.6942

历史事件查询和统计端点分别约加速 1.59× 与 1.69×。热力图和 48×1024 forecast 的完整 JSON 响应本轮略慢，说明它们主要受 Python 对象构造、JSON 序列化和 gzip 压缩限制；不应宣称 API 全面加速。

优化后 API 冷启动 0.511s，空闲 RSS 125.75 MiB，基准期间峰值 RSS 137.39 MiB。

8. 测量边界与后续加固

1. pipeline variant 各运行一次且顺序固定，小差异可能受系统调度影响；
2. `peak_rss_mib` 是进程树 RSS 求和，共享页可能重复计算，不等同于物理 PSS；
3. API 是单客户端 loopback，不包含公网、反向代理、浏览器渲染和并发压力；
4. 统计缓存按当前单进程顺序运行设计；并行 writer 场景应增加 file lock 或唯一临时文件；
5. FP16/INT8 都由显式质量与速度门槛控制，本轮生产配置保持 FP32；
6. 正式结果位于 `outputs/week7_performance/final_system_v5/`，配置为 `configs/week7_performance.yaml`。